UNIVERZITET U NIŠU
ELEKTRONSKI FAKULTET

DETEKCIJA TEMA U *Youtube* KOMENTARIMA FANOVA EMISIE "*GOING SEVENTEEN*" PRIMENOM BERTopic I DRUGIH MODELA

Seminarski rad

Studijski program: Veštačka inteligencija i mašinsko učenje

Student:
Jovana Malinović, br. ind. 2133

Mentor:
Prof. dr. Miloš Bogdanović

Niš, mart 2026.

SADRŽAJ

UVOD **1**

1. SEVENTEEN I EMISIJA "*GOING SEVENTEEN* " **2**

2. TEKST MAJNING I DETEKCIJA TEMA **4**

2.1. Specifičnost Youtube komentara 4

2.2. Osnovni koncepti modeliranja tema 6

3. PREGLED POSTOJEĆIH MODELA **7**

3.1. Latent Dirichlet allocation (LDA) 7

3.2. Non-negative matrix factorization (NMF) 8

3.3. BERTopic 8

3.3.1. Sentence Transformers i generisanje embedinga 9

3.3.2. UMAP - redukcija dimenzionalnosti 10

3.3.3. HDBSCAN - klasterovanje zasnovano na gustini 10

3.3.4. c-TF-IDF - generisanje ključnih reči tema 11

4. SKUP PODATAKA **12**

4.1. Izvor podataka 12

4.2. Strategije selekcije videa 12

4.3. Prikupljanje komentara 13

5. PREDOBRADA I REPREZENTACIJA TEKSTA **14**

5.1. Predobrada teksta 14

5.1.1. Normalizacija 14

5.1.2. Tokenizacija 15

5.1.3. Uklanjanje stop reči 16

5.1.4. Lematizacija 16

5.2. Reprezentacija teksta 17

6. DETEKECIJA TEMA I ANALIZA **18**

6.1. Statistika skupa podataka 18

6.2. Filtriranje i klasifikacija wish komentara 19

6.3. Predobrada teksta 20

6.4. Rezultati LDA i NMF modela 20
6.5. Rezultati BERTopic modela - Varijanta A (Sentence Transformers) 23
6.6. Rezultati BERTopic modela - Varijanta B (Word2Vec) 25
6.7. Komparativna analiza svih modela 27
6.8. Automatsko otkrivanje podoblasti u kategoriji “Other“ 28
6.9. Analiza po članovima grupe i tipu epizode 29
7. NEDOSTACI I POTENCIJALNA UNAPREĐENJA 30
ZAKLJUČAK 31
LITERATURA 32

UVOD

U savremenom digitalnom okruženju, društvene mreže i platforme za deljenje sadržaja predstavljaju izuzetno bogat izvor nestrukturiranih podataka koji odražavaju stavove, emocije i interesovanja korisnika. Ekspanzija video-platformi donela je novi oblik javnog diskursa, komentare korisnika koji nastaju spontano, bez uređivačke kontrole i u realnom vremenu. Među njima, YouTube zauzima posebno mesto kao najveća svetska platforma za video sadržaj, sa više od 2,5 milijardi aktivnih korisnika mesečno i milijardama komentara koji pokrivaju gotovo sve domene ljudske aktivnosti **Error! Reference source not found.**. Ovakav obim podataka predstavlja izuzetno vredan, ali i metodološki zahtevan izvor za istraživanje obrazaca komunikacije i dinamike unutar različitih onlajn zajednica.

Komentari na YouTube videima su, sa stanovišta obrade prirodnog jezika (NLP), specifičan tip podataka: kratki, nestrukturirani tekstovi koji obiluju slengom, emotikonima, referencama na kulturne kontekste i greškama nastalim pri brzom kucanju. Višejezičnost dodatno komplikuje analizu, jer uvodi izazove vezane za detekciju jezika, mašinsko prevođenje i semantičku koherentnost modela. Upravo ove karakteristike čine automatsku analizu komentara istovremeno istraživački izazovnom i potencijalno visoko informativnom.

Poseban interes u ovom radu usmeren je na analizu komentara fanova emisije "*Going Seventeen*", reality formata korejske muzičke grupe SEVENTEEN, koji okuplja globalnu zajednicu fanova poznatu kao *Carat*. Ova zajednica se odlikuje visokim stepenom angažovanosti, specifičnim oblicima komunikacije i velikim brojem komentara na YouTube platformi. Analiza ovih komentara omogućava uvid u teme koje najviše privlače pažnju publike, načine na koje fanovi izražavaju mišljenje, kao i njihove želje i očekivanja u vezi sa budućim sadržajem. U radu se primenjuju savremeni modeli za detekciju tema, sa posebnim fokusom na BERTopic model, uz poređenje sa tradicionalnim pristupima kao što su LDA i NMF, kako bi se identifikovale i interpretirale dominantne teme unutar fan zajednice.

1. SEVENTEEN I EMISIJA "*GOING SEVENTEEN* "

SEVENTEEN je južnokorejska muzička grupa osnovana od strane kompanije Pledis Entertainment (HYBE). Grupa ima 13 članova, kao što vidimo na slici 1.1., i poznata je po specifičnoj organizaciji u tri podgrupe (hip-hop, vocal i performance), kao i po visokom nivou kreativne autonomije u produkciji muzike i koreografija. Zahvaljujući ovim karakteristikama, oni su izgradili veliku globalnu bazu fanova poznatu kao *Carat*, koja je izrazito aktivna na društvenim mrežama i platformama za deljenje video sadržaja.

Slika 1.1. Grupa SEVENTEEN

Pored muzičkog uspeha, SEVENTEEN se izdvaja i po visokom nivou timske dinamike i jasno definisanim ulogama članova unutar grupe. Podela na tri podgrupe (hip-hop, vocal i performance) omogućava efikasnu raspodelu odgovornosti, ali i doprinosi raznovrsnosti sadržaja koji grupa proizvodi. Ova organizacija se ne odražava samo na muziku, već i na njihov zabavni sadržaj, gde se jasno uočavaju različiti tipovi ličnosti, humor i međusobni odnosi između članova. Upravo ova autentična interakcija predstavlja jedan od ključnih razloga popularnosti grupe, jer fanovi ne prate samo njihov umetnički rad, već i međusobne odnose i razvoj članova kroz vreme.

Grupa je posebno prepoznatljiva po sopstvenom zabavnom sadržaju, među kojima se izdvaja emisija "*Going Seventeen*" plasirana na Youtube platformi, prikazano na slici 1.2. Ova emisija predstavlja kombinaciju *reality* i *variety* formata, u kojoj članovi učestvuju u različitim igrama, izazovima, improvizovanim skečevima i tematskim epizodama. Format emisije varira od epizode do epizode i uključuje popularne koncepte kao što su "mafia game", "escape room", putovanja i slično.

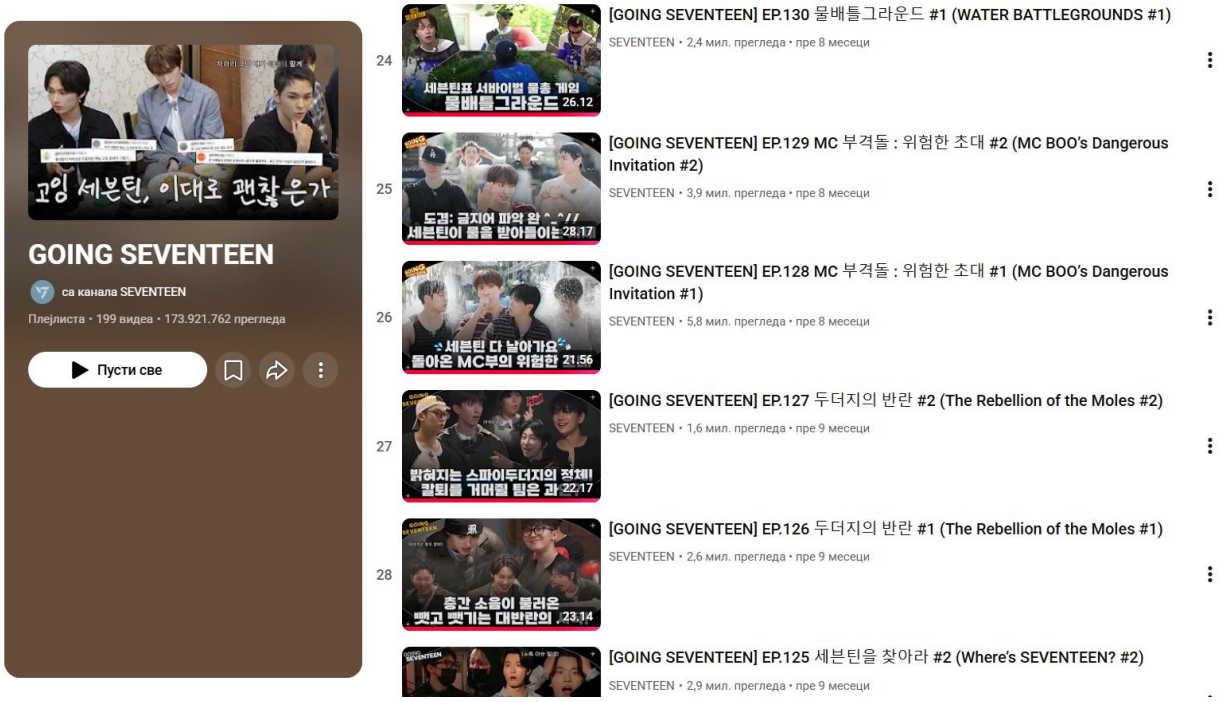

Slika 1.2. Emisija "*Going Seventeen*"

"*Going Seventeen*" je stekao značajnu popularnost ne samo među fanovima grupe, već i širom YouTube zajednice, zbog svog humora, spontanosti i dinamične interakcije između članova. Komentari ispod ovih videa predstavljaju bogat izvor podataka za analizu, jer reflektuju reakcije publike, omiljene momente, ali i želje fanova za budući sadržaj. Upravo zbog toga ova emisija predstavlja pogodan i relevantan skup podataka za primenu metoda detekcije tema u okviru ovog istraživanja.

2.TEKST MAJNING I DETEKCIJA TEMA

Tekst majning, ili rudarenje teksta, podrazumeva skup postupaka za automatsko izvlačenje korisnih informacija i znanja iz nestrukturiranih ili polustrukturiranih tekstualnih podataka. Za razliku od relacionih baza podataka gde su informacije precizno organizovane u unapred definisane tabele, tekstualni podaci su po prirodi neformalni, višeznačni i teško obradivi konvencionalnim analitičkim metodama. Tekst majning obuhvata tehnike iz računarske lingvistike, statistike i mašinskog učenja, a primenjuje se u oblastima kao što su analiza sentimenta, prepoznavanje entiteta, klasifikacija dokumenata i detekcija tema.

Detekcija tema je specifična grana tekst majninga koja se bavi automatskim otkrivanjem latentnih tematskih struktura u velikim kolekcijama tekstova. Ključna odlika ove metode je da je nenadgledana odnosno teme se ne definišu unapred i ručno, već ih model sam izvodi direktno iz podataka, bez ikakvih oznaka ili supervizije. Rezultat su grupe reči koje semantički koherentno opisuju određenu tematsku celinu, na osnovu kojih istraživač interpretira o čemu korpus govori.

2.1. Specifičnost Youtube komentara

YouTube komentari su posebno zahtevan tip podataka za primenu NLP tehnika, i to iz nekoliko razloga koji direktno motivišu metodološke izbore opisane u nastavku ovog rada.

Kratkoća i fragmentarnost su možda najočiglednije karakteristike. Dok su klasični NLP modeli razvijani i evaluirani na novinarskim tekstovima, naučnim radovima ili knjigama, prosečan YouTube komentar sadrži svega nekoliko reči do dve-tri rečenice. Ovako kratki tekstovi nose mali statistički signal po dokumentu, što direktno otežava primenu modela zasnovanih na frekvenciji reči kao što je na primer LDA. Probabilistički zaključak postaje nepouzdan kada je distribucija reči unutar dokumenta suviše retka [1]. Primer možemo videti na slici 2.1.

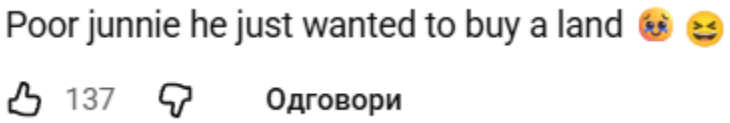

Slika 2.1. Primer kratkog fragmentarnog komentara

Neformalni jezik i sleng su gotovo univerzalna karakteristika. Korisnici koriste skraćenice (“lmao“, “omg“, “ngl“), neologizme, fanovski specifičan vokabular i izraze koji ne postoje u standardnim rečnicima. U kontekstu K-pop fan zajednice ovo uključuje i interne šale i meme-ove koji su razumljivi samo dugogodišnjim fanovima [6]. Primer možemo videti na slici 2.2.

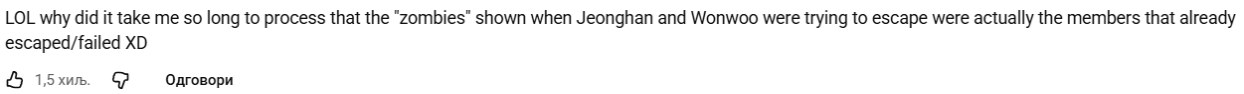

Slika 2.2. Primer komentara sa slengom

Višejezičnost je naročito izražena u zajednicama globalnih K-pop fanova, gde koegzistiraju engleski, korejski, kineski, španski, portugalski i brojni drugi jezici. Ova heterogenost komplikuje modeliranje jer modeli trenirani na jednom jeziku ne mogu direktno da procesiraju tekst na drugom bez posebnih tehnika kao što su višejezični embedinzi [6]. U ovom radu je primenjen filter za engleski jezik, što je svestan metodološki kompromis koji omogućava fokusiraniju analizu ali istovremeno isključuje ostale fan zajednice iz rezultata. Primer možemo videti na slici 2.3.

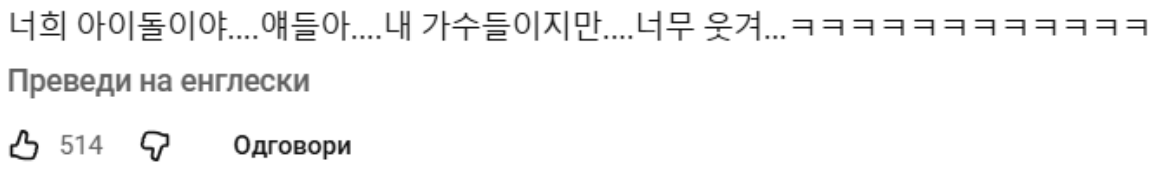

Slika 2.3. Primer komentara na korejskom jeziku

Repetitivnost je karakteristika koja se javlja na popularnim videima gde mnogi korisnici ostavljaju komentare sličnog ili gotovo identičnog sadržaja, reagujući na iste momente ili izgovarajući iste reči. Ovo može iskriviti rezultate modeliranja ka temama koje su statistički dominantne usled ponavljanja, a ne zbog stvarne raznolikosti diskursa [1]. Primere možemo videti na slici 2.4.

Slika 2.4. Primeri repetitivnih komentara

2.2. Osnovni koncepti modeliranja tema

Pre pregleda konkretnih modela, korisno je precizirati nekoliko ključnih pojmova koji se koriste u ovoj oblasti.

Tema je u kontekstu automatskog modeliranja distribucija verovatnoća nad rečnikom. Svaka reč u rečniku ima određenu verovatnoću da pripada datoj temi, a teme se opisuju rečima koje imaju visoku verovatnoću u okviru te distribucije. Intuitivno, tema o sportu ima visoku verovatnoću za reči kao što su "gol", "igrač", "meč", i nisku za reči poput "recept" ili "kamera".

Dokument je u ovom kontekstu svaki diskretni tekstualni zapis, što u ovom radu odgovara jednom komentaru. Modeli pretpostavljaju da je svaki dokument mešavina jedne ili više tema u različitim proporcijama, što je generativna pretpostavka zajednička svim modelima opisanim u ovom radu.

Embeding (engl. embedding) je numerička vektorska reprezentacija teksta u kontinualnom vektorskom prostoru, takva da su semantički slični tekstovi geometrijski bliski [1]. Savremeni pristupi poput BERTopic-a grade modeliranje tema na osnovu embedinga umesto na osnovu frekvencija reči, što je fundamentalna promena paradigme. Umesto da pitaju koje reči se zajedno pojavljuju, pitaju koji tekstovi semantički liče jedan na drugi.

Evaluacija modela za detekciju tema je individualan problem jer ne postoji jedinstven "tačan" skup tema za dati korpus. Najčešće korišćene automatske metrike su koherentnost teme, koja meri semantičku srodnost reči unutar iste teme, i raznolikost tema, koja meri razliku između reči koje opisuju različite teme. Pored automatskih metrika, kvalitativna interpretabilnost ostaje ključan kriterijum u praksi odnosno, tema čije ključne reči nemaju smisla za domenskog eksperta je loša tema bez obzira na numeričku vrednost metrike.

3. PREGLED POSTOJEĆIH MODELA

Modeliranje tema je oblast nenadgledanog mašinskog učenja koja se bavi automatskim otkrivanjem latentnih tematskih struktura u tekstualnim kolekcijama. Osnovna ideja je da model sam, bez ikakvih unapred zadatih oznaka, pronađe o čemu se govori u skupu dokumenata, grupišući reči i tekstove koji se pojavljuju u sličnim kontekstima. Od kada je predstavljen LDA model, ova oblast je prošla kroz nekoliko razvojnih faza, od čisto statističkih pristupa zasnovanih na frekvenciji reči, preko algebarskih metoda faktorizacije matrica, do savremenih neuralnih modela koji koriste kontekstualne reprezentacije teksta zasnovane na transformer arhitekturama. Svaka od ovih generacija modela donela je napredak u pogledu semantičke preciznosti, ali i nove izazove u pogledu računarske složenosti i interpretabilnosti rezultata. U nastavku su opisani najznačajniji modeli relevantni za predmetno istraživanje, a izbor BERTopic modela kao primarnog alata motivisan je upravo ograničenjima starijih pristupa kada se primene na kratke, neformalne tekstove kakvi su komentari na društvenim mrežama [1]. U nastavku su opisani najznačajniji modeli relevantni za istraživanje.

3.1. Latent Dirichlet allocation (LDA)

LDA je verovatno najpoznatiji model za modeliranje tema i dugo je bio *de facto* standard u ovoj oblasti. Model počiva na generativnoj probabilističkoj pretpostavci o tome kako nastaju tekstovi gde se svaki dokument posmatra kao mešavina tema, a svaka tema kao distribucija nad rečima rečnika. Konkretno, LDA pretpostavlja da je autor teksta najpre "izabrao" teme o kojima će pisati prema nekoj raspodeli, a zatim za svaku reč nasumično odabrao temu iz te raspodele i iz te teme odabrao konkretnu reč [2]. Cilj modela je da iz posmatranih reči rekonstruiše ovaj skriveni generativni proces tj. da proceni koje su teme zastupljene u svakom dokumentu i koje su reči karakteristične za svaku temu.

Treniranje se vrši algoritmima varijacione Bajesove inferencije ili Gibbsovim uzorkovanjem koji iterativno ažuriraju procene raspodele tema. Jedan od praktičnih problema je to što broj tema K mora biti unapred zadat kao hiperparametar što znači da istraživač mora da proba više vrednosti i proceni koja daje najsmislenije rezultate, što nije uvek jednostavno niti jednoznačno. Još veće ograničenje za predmetno istraživanje je to što LDA tretira tekst kao "vreću reči" (*bag of words*) i potpuno ignoriše redosled reči i kontekst u kom se pojavljuju [6]. Za formalne i duže tekstove ovo ponekad nije kritičan problem, ali za komentare tipa *"mingyu carried this whole episode lmaooo"* gubi se dosta semantičkog sadržaja. Model ne razume da su "*carried*," "*episode"* i "*lmaooo"* zajedno signal entuzijazma prema određenom članu grupe u određenom kontekstu. Uprkos ovim ograničenjima, LDA ostaje standardna bazna linija u istraživanjima modeliranja tema zbog dostupnosti implementacija i lake interpretabilnosti rezultata, i kao takav biće korišćen za poređenje u ovom radu.

3.2. Non-negative matrix factorization (NMF)

NMF pristupa problemu modeliranja tema iz algebarskog ugla, potpuno drugačije od LDA [3]. Polazna tačka je matrica dokument-termin V dimenzija n × m, gde svaki red predstavlja jedan dokument, svaka kolona jednu reč iz rečnika, a vrednosti u matrici tipično odgovaraju TF-IDF težinama. NMF faktorizuje ovu matricu na dve manje matrice nenegativnih vrednosti, W dimenzija n × k, koja opisuje koliko je svaka od k tema zastupljena u svakom dokumentu, i H dimenzija k × m, koja opisuje koliko je svaka reč karakteristična za svaku temu. Optimizacija se vrši minimizacijom mere odstupanja između originalne matrice i njene aproksimacije WH, najčešće korišćenjem Frobeniusove norme.

Ograničenje nenegativnosti nije samo matematička konvencija već ono ima semantički smisao jer podstiče aditivne reprezentacije u kojima se svaka tema može interpretirati kao zbir karakterističnih reči bez negativnih korekcija. Empirijska istraživanja pokazuju da NMF često generiše interpretabilnije teme od LDA na kratkim tekstovima [4], delom zbog toga što je optimizacioni proces direktniji i manje podložan problemima konvergencije koji se javljaju kod probabilističkih modela. Ipak, NMF deli isti fundamentalni nedostatak sa LDA, *bag-of-words* reprezentacija ne razume semantičke odnose između reči, a broj tema i dalje mora biti zadat unapred [9]. Zbog toga NMF, kao i LDA, nije najpogodniji izbor za analizu komentara koji obiluju sa slengom, emotikonima i kulturno specifičnim referencama.

3.3. BERTopic

BERTopic je modularni pipeline koji kombinuje prednosti prethodnih pristupa i rešava većinu njihovih ključnih nedostataka. Koristi semantički bogate neuralne embedinge koji razumeju kontekst, automatski određuje broj tema iz podataka, podržava višejezičnu analizu kroz višejezične Sentence Transformers modele, i generiše visoko interpretabilne opise tema kroz c-TF-IDF proceduru [8]. Pored svega toga, modularna arhitektura omogućava da se svaka komponenta pipeline-a nezavisno konfiguriše ili zameni alternativnim algoritmom, što ga čini izuzetno fleksibilnim za različite tipove podataka i istraživačke kontekste [2]. Upravo ova kombinacija osobina čini BERTopic najprikladnijim izborom za analizu komentara u ovom radu.

BERTopic model funkcioniše kao modularan pipeline koji transformiše sirove tekstualne dokumente u interpretabilne tematske klastere kroz četiri uzastopna koraka. Ono što ga čini posebnim u odnosu na modele opisane u prethodnom poglavlju nije jedna konkretna tehnička inovacija, već upravo ta modularnost gde se svaki korak pipeline-a može nezavisno konfigurisati, zameniti ili proširiti u zavisnosti od karakteristika podataka i istraživačkih potreba. U nastavku su detaljno opisane sve četiri komponente, kao i specifična konfiguracija primenjena u ovom istraživanju. U nastavku možemo videti kako izgleda arhitektura BERTopic modela na slici 3.1., koja će biti dodatno objašnjena.

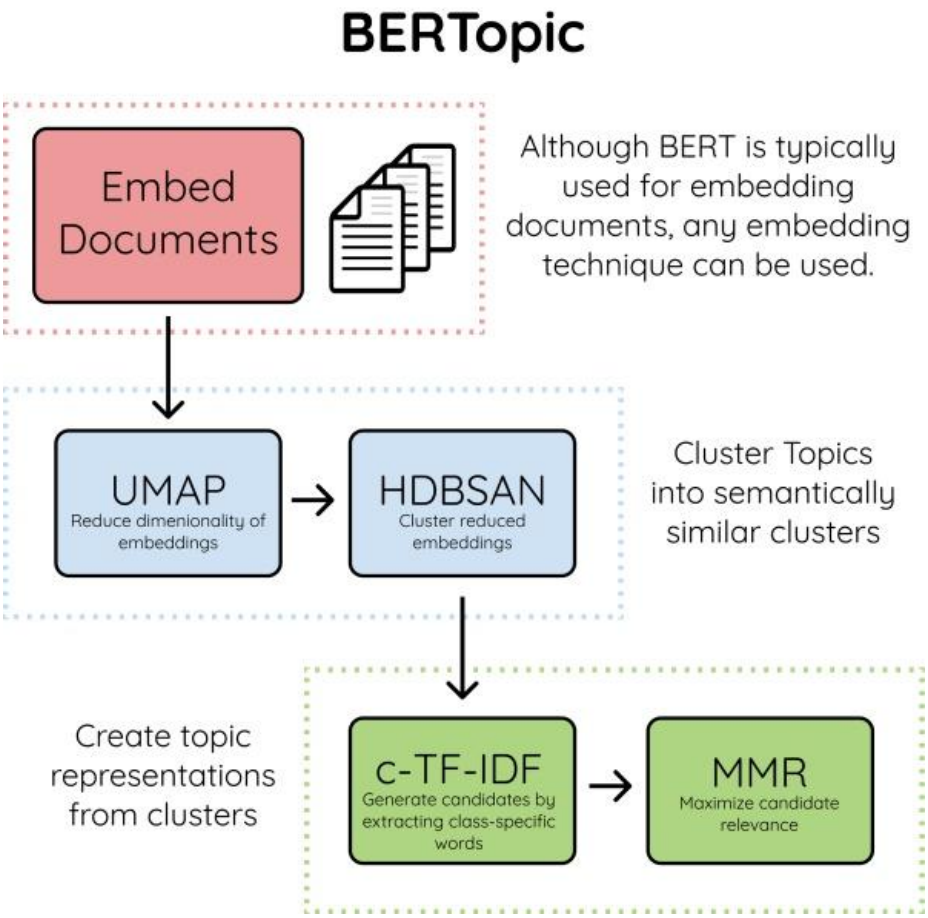

Slika 3.1. Arhitektura BERTopic modela

3.3.1. Sentence Transformers i generisanje embedinga

Prvi korak u BERTopic pipeline-u je pretvaranje tekstualnih dokumenata u numeričke vektore koji čuvaju semantičko značenje teksta. Ovi vektori nazivaju se embedinzi, a njihova ključna osobina je da se semantički slični tekstovi nalaze blizu jedni drugih u vektorskom prostoru, dok su semantički različiti tekstovi udaljeni. Upravo ova osobina čini ih prikladnom osnovom za kasniji korak klasterovanja.

Embedinzi se generišu korišćenjem pretrenirane arhitekture zasnovane na BERT modelu (Bidirectional Encoder Representations from Transformers). BERT je bidirekcioni transformer model koji pri kodiranju svake reči uzima u obzir čitav kontekst rečenice i reči koje prethode i reči koje slede [10]. To znači da ista reč u različitim rečenicama može biti kodirana različitim vektorom u zavisnosti od konteksta, što je fundamentalna razlika u odnosu na starije modele poput Word2Vec reprezentacije, koji svakoj reči dodeljuju jedan fiksni vektor bez obzira na kontekst [9]. Na primer, reč “live” u komentarima "they should live together" i "this performance was so live" dobija različite reprezentacije, što je semantički ispravno.

3.3.2. UMAP - redukcija dimenzionalnosti

Embedinzi generisani u prethodnom koraku postoje u 384-dimenzionalnom prostoru. Ovo je problem iz dva razloga. Prvo, algoritmi klasterovanja se loše ponašaju u prostorima visoke dimenzionalnosti. Pojava poznata kao kletva dimenzionalnosti (curse of dimensionality) podrazumeva da u visokim dimenzijama euklidske distance između tačaka postaju uniformne i gube diskriminativnu moć, što čini klasterovanje praktično beskorisnim [5]. Drugo, 384 dimenzije su računarski zahtevne za obradu na velikim skupovima podataka. Iz ovih razloga BERTopic pre klasterovanja primenjuje redukciju dimenzionalnosti.

Algoritam koji se koristi je UMAP (Uniform Manifold Approximation and Projection). UMAP funkcioniše na principu aproksimacije topološke strukture podataka gde najpre konstruiše graf bliskosti u originalnom prostoru visoke dimenzionalnosti, pri čemu svaka tačka poznaje svoje najbliže susede, a zatim optimizuje niskodimenzionalnu reprezentaciju koja što vernije reprodukuje ovu lokalnu i globalnu strukturu. Rezultat je projekcija podataka u prostor znatno manjih dimenzija, tipično između 2 i 10, pri čemu su sačuvani odnosi bliskosti između tačaka [5].

Važno je napomenuti zašto je UMAP bolji izbor od PCA (Principal Component Analysis), koja je možda intuitivnija alternativa. PCA je linearna metoda koja pronalazi pravce maksimalne varijanse u podacima ali semantički prostori koje generišu transformer modeli imaju složene nelinearne strukture koje PCA jednostavno ne može da zahvati. UMAP je nelinearna metoda i znatno bolje čuva lokalne klasterske strukture, što je direktno relevantno za kasniji korak klasterovanja. Empirijska istraživanja pokazuju i da UMAP postiže bolje rezultate od alternativne nelinearne metode t-SNE, uz kraće vreme izvršavanja na velikim skupovima podataka [5].

3.3.3. HDBSCAN - klasterovanje zasnovano na gustini

Nakon što su embedinzi svedeni na manji broj dimenzija, sledeći korak je njihovo grupisanje u tematske klastere. BERTopic za ovu svrhu koristi algoritam HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise), kao hijerarhijsko proširenje popularnog DBSCAN algoritma.

Osnovna ideja HDBSCAN algoritma je da klastere definiše kao guste regione u prostoru tj. kao grupe tačaka koje su međusobno bliske i okružene tačkama niže gustine. Za razliku od K-means algoritma koji pretpostavlja sferične klastere uniformne veličine i zahteva unapred zadati broj klastera K, HDBSCAN nema nikakve pretpostavke o obliku klastera i automatski određuje njihov broj na osnovu strukture podataka. Ovo je posebno važno za analizu komentara jer teme u stvarnim podacima retko imaju pravilne, sferične oblike u vektorskom prostoru [2].

Algoritam funkcioniše u nekoliko faza. Najpre se za svaku tačku računa njena gustina na osnovu rastojanja do k-tog najbližeg suseda. Zatim se konstruiše minimalno obuhvatajuće stablo (minimum spanning tree) koje opisuje strukturu podataka, a iz ovog stabla se gradi hijerarhija klastera, dendogram, koji prikazuje kako se klasteri spajaju i razdvajaju pri različitim vrednostima

parametra gustine. Konačno, iz ove hijerarhije se ekstrahuju stabilni klasteri kao oni koji opstaju kroz širok opseg vrednosti gustine.

Posebno važna osobina HDBSCAN algoritma je tretman tačaka koje ne pripadaju nijednom dovoljno gustom klasteru. Ove tačke se označavaju kao šum i dodeljuju se posebnoj temi sa oznakom -1. U kontekstu BERTopic modela, ova outlier tema predstavlja skup komentara koji su previše specifični, kratki, atipični ili jednostavno previše raznovrsni da bi bili grupisani u koherentnu temu. Prisustvo velikog broja komentara u -1 temi obično ukazuje na to da su parametri modela previše restriktivni ili da skup podataka sadrži mnogo šuma, što je čest slučaj kod komentara na društvenim mrežama.

3.3.4. c-TF-IDF - generisanje ključnih reči tema

Kada HDBSCAN dodeli svaki komentar određenom klasteru, znamo koje komentare "grupiše" svaka tema ali još uvek ne znamo kako da je opišemo rečima. Upravo to rešava poslednji korak BERTopic pipeline-a: procedura c-TF-IDF (class-based Term Frequency - Inverse Document Frequency), koja je centralna inovacija ovog modela. [2]

Ideja je elegantna: svi komentari koji pripadaju istoj temi konkatenuju se u jedan veliki pseudo-dokument koji reprezentuje tu temu. Zatim se na skupu svih pseudo-dokumenata, po jedan za svaku temu, primenjuje modifikovana TF-IDF mera. Frekvencija termina (TF) se računa unutar pseudo-dokumenta teme, dok se inverzna frekvencija dokumenata (IDF) računa u odnosu na sve teme kao klase. Formalno:

$$c - TF - IDF_{t,c} = \frac{f_{t,c}}{|c|} * \log\left(1 + \frac{m}{\sum_j F_{t,j}}\right),$$

gde je $f_{t,c}$ frekvencija termina t u klasi c, $|c|$ ukupan broj reči u klasi c, m ukupan broj reči u svim klasama, a $\sum_j F_{t,j}$ ukupna frekvencija termina t kroz sve klase [2].

Rezultat su reči koje su istovremeno česte unutar date teme i retke u ostatku korpusa što ih čini visoko distinktivnim i semantički reprezentativnim upravo za tu temu. Ovo je ključna razlika u odnosu na to da bi se teme opisivale rečima koje su globalno bliske centroidu klastera u vektorskom prostoru, kao što to radi Top2Vec. Na primer, reč “seventeen” bi verovatno bila bliska centroidu gotovo svih klastera jer se pojavljuje u velikom broju komentara ali c-TF-IDF je neće visoko rangirati za nijednu konkretnu temu jer je ravnomerno rasprostranjena po celom korpusu. Umesto toga, za temu o, recimo, plesnim nastupima biće visoko rangirane reči poput “choreography”, “dance”, “sync” i “moves”, koje su karakteristične baš za tu temu.

Na izlazu iz c-TF-IDF procedure moguće je dodatno primeniti Maximal Marginal Relevance (MMR) metod, koji balansira relevantnost i raznovrsnost odabranih ključnih reči, čime se izbegava redundansa i obezbeđuje informativniji opis tema [2].

4. SKUP PODATAKA

4.1. Izvor podataka

Za prikupljanje komentara korišćen je YouTube Data API v3, zvanični interfejs koji Google pruža za programski pristup sadržaju YouTube platforme. API omogućava preuzimanje različitih tipova podataka poput metapodataka videa (naslov, broj pregleda, datum objave, trajanje), statistika kanala, kao i komentara sa svim pratećim informacijama poput broja lajkova i datuma objave komentara. Autentifikacija se vrši putem API ključa koji se generiše u okviru Google Cloud konzole.

Jedno od ključnih ograničenja YouTube Data API v3 je sistem kvota. Svaki API nalog raspolaže sa 10.000 jedinica dnevno, pri čemu različite operacije troše različit broj jedinica. Pretraga videa po naslovu (search.list) troši 100 jedinica po zahtevu, dok preuzimanje komentara (commentThreads.list) troši 1 jedinicu po stranici rezultata sa maksimalno 100 komentara po stranici. Tako je za svaki video najpre je izvršena pretraga po naslovu kako bi se dobio video ID, a zatim su preuzeti svi dostupni komentari na engleskom iteracijom kroz stranice rezultata korišćenjem list_next mehanizma za paginaciju.

4.2. Strategije selekcije videa

Skup podataka obuhvata komentare sa ukupno 20 videa YouTube kanala "*Going Seventeen",* podeljenih u dve grupe od po 10 videa. Ovakva podela nije slučajna već je njen cilj da omogući komparativnu analizu koja je jedan od centralnih doprinosa ovog rada.

Prvu grupu čini 10 najgledanijih videa kanala. Ovi videi reprezentuju "klasične" epizode koje su tokom vremena privukle najveću publiku, najčešće zbog toga što su imale posebno zabavne, emotivne ili ikonične momente koji su se širili putem društvenih mreža i privlačili nove gledaoce. Komentari ispod ovih videa akumulirali su se tokom dužeg vremenskog perioda i potiču od gledalaca različitih "generacija" fanove zajednice, od dugogodišnjih fanova koji su pratili emisiju od početka, do novih gledalaca koji su video otkrili mnogo kasnije. Može se pretpostaviti da teme u ovim komentarima odražavaju ono što je u emisiji ostalo trajno upečatljivo i referentno unutar zajednice.

Drugu grupu čini 10 najskorije objavljenih videa u trenutku prikupljanja podataka. Ovi videi reprezentuju aktuelnu diskusiju fan zajednice i odražavaju trenutne trendove, reakcije na nedavne događaje u grupi i teme koje su u fokusu zajednice u datom trenutku. Komentari su vremenski koncentrisani, uglavnom objavljeni u kratkom periodu nakon izlaska videa, kada je angažovanost zajednice najveća.

Ova podela omogućava da se u analizi odgovori na pitanje da li priroda diskusije zavisi od toga koliko je video star i koliko je gledan, što je pitanje koje do sada nije sistematski istraživano u kontekstu K-pop fan zajednica na YouTube platformi.

4.3. Prikupljanje komentara

Proces prikupljanja odvijao se u dva koraka za svaki video. Najpre je funkcijom get_video_id() izvršena pretraga YouTube API-ja po tačnom naslovu videa kako bi se dobio jedinstveni video identifikator, a zatim je funkcijom get_comments() izvršeno preuzimanje komentara uz iteraciju kroz sve stranice rezultata. Između svakog zahteva uvedena je pauza od jedne sekunde (time.sleep(1)) kako bi se izbegli problemi sa prekoračenjem kvote i ograničenjima brzine slanja zahteva.

Važno je napomenuti da je u originalnoj implementaciji filtriranje po jeziku ugrađeno direktno u korak prikupljanja odnosno samo komentari za koje biblioteka langdetect detektuje engleski jezik bivaju sačuvani, dok se ostali odbacuju već u ovoj fazi. Ovo znači da korejski komentari nisu uključeni u inicijalni skup podataka, što je odluka koja ima praktičnu motivaciju, smanjuje veličinu skupa i pojednostavljuje dalju obradu, ali i ograničenje koje treba uzeti u obzir pri interpretaciji rezultata, s obzirom na to da korejska fan zajednica time nije zastupljena u analizi.

Za svaki prikupljeni komentar sačuvani su sledeći atributi: tekst komentara, broj lajkova, datum objave, identifikator videa, naslov videa i oznaka tipa videa (popularni/najskoriji). Rezultati su sačuvani u CSV fajlu.

5. PREDOBRADA I REPREZENTACIJA TEKSTA

5.1. Predobrada teksta

Predobrada tekstualnih podataka obuhvata skup transformacija koje se primenjuju na sirovi tekst pre prosleđivanja modelu, sa ciljem uklanjanja šuma, smanjenja dimenzionalnosti rečnika i ujednačavanja reprezentacije. Kvalitet sprovedene predobrade direktno utiče na performanse modela. Odabir konkretnih tehnika zavisi od karakteristika korpusa i arhitekture modela koji se koristi.

5.1.1. Normalizacija

Normalizacija teksta obuhvata skup transformacija čiji je cilj ujednačavanje tekstualnih podataka tj. svođenje različitih površinskih formi iste informacije na zajednički, standardni oblik [7]. Bez normalizacije, iste reči ili koncepti mogu biti reprezentovani na bezbroj različitih načina, što povećava dimenzionalnost rečnika i otežava generalizaciju modela.

Case folding je pretvaranje svih znakova u mala slova i jedna je od najjednostavnijih i najčešće primenjivanih tehnika normalizacije [8]. Bez nje, "Smith", "smith" i "SMITH" tretiraju se kao tri različita tokena iako predstavljaju isti entitet.

Unicode normalizacija rešava problem različitih kodiranja istih znakova. Na primer, slovo "é" može biti kodirano kao jedan Unicode karakter ili kao kombinacija slova "e" i dijakritičkog znaka [9]. Web *scraped* podaci često sadrže mešavinu različitih Unicode formi što rezultuje veštačkim duplikatima u rečniku. Standardna praksa je primena NFC ili NFKC normalizacije koja sve znakove svodi na kanonski oblik.

Uklanjanje i zamena specijalnih elemenata podrazumeva sistematsko tretiranje URL-ova, korisničkih oznaka, brojeva i ostalih ne-leksičkih elemenata. URL-ovi se zamenjuju neutralnim tokenom <URL>, brojevi tokenom <NUM>, a HTML tagovi se u potpunosti uklanjaju. Ovaj korak direktno smanjuje veličinu rečnika eliminisanjem tokena koji nemaju semantičku vrednost za klasifikaciju.

Na nivoa projekta uklonjeni su HTML tagovi i entiteti koji nastaju pri preuzimanju teksta putem API-ja (npr. <b>, &, <br>), URL-ovi i @mentions, a sav tekst je preveden u mala slova. Uklanjanje HTML artefakata posebno je važno jer scraped tekst sistematski sadrži tehničke ostatke koji povećavaju veličinu rečnika bez ikakve semantičke vrednosti. Svaki jedinstveni URL tretira se kao zasebna reč koja doprinosi jednu beskorisnu dimenziju rečniku [9], pa je standardna praksa njihovo uklanjanje u ovom koraku.

5.1.2. Tokenizacija

Tokenizacija je proces razdvajanja teksta na manje jedinice, tokene, koje predstavljaju osnovne gradivne elemente za dalju obradu [7]. Ona je prvi i neophodan korak u svakom NLP pipeline-u jer model ne može direktno procesirati sirovi string znakova. Izbor strategije tokenizacije ima značajan uticaj na veličinu rečnika i kvalitet reprezentacije teksta [8]. Možemo videti jedan primer tokenizacije na slici 5.1.

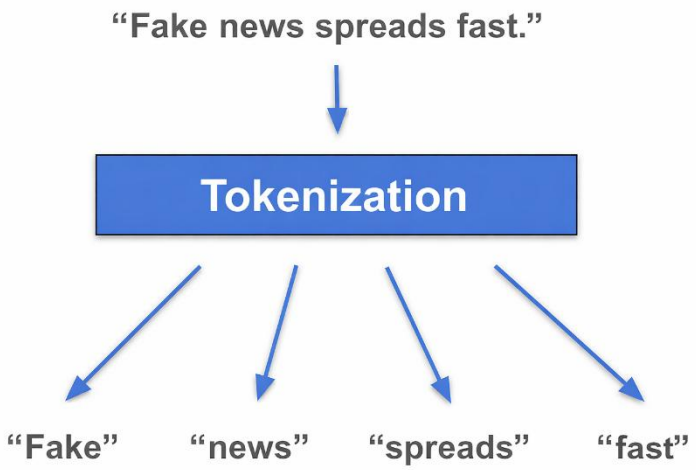

5.1. Primer tokenizacije

Word tokenizacija razdvaja tekst na pojedinačne reči korišćenjem razmaka i interpunkcije kao graničnika. Ovo je najintuitivniji pristup i dobro funkcioniše za standardne tekstove na engleskom jeziku [8]. Međutim, ima ograničenja gde ne zna kako da tretira složenice poput "New York", kontraktovane oblike poput "don't" ili reči sa crticom poput "state-of-the-art". Alati poput NLTK *word_tokenize* rešavaju deo ovih problema pravilima zasnovanim na lingvističkim konvencijama.

Subword tokenizacija razdvaja reči na manje jedinice, prefikse, sufikse i korene, što je posebno korisno za retke reči i morfološki bogate jezike. Algoritmi poput BPE (*Byte Pair Encoding*) i WordPiece koji koristi BERT, iterativno spajaju najčešće parove znakova ili subword jedinica dok ne dostignu željenu veličinu rečnika. Ključna prednost subword tokenizacije je sposobnost obrade nepoznatih reči, odnosno reč koja nije viđena tokom treniranja može se rastaviti na poznate subword komponente.

Sentence tokenizacija razdvaja tekst na rečenice i koristi se kada je analiza na nivou rečenice relevantnija od analize na nivou reči [8].

Na nivou projekta tekst je podeljen na tokene korišćenjem NLTK word_tokenize funkcije, koja ispravno tretira skraćenice i granične slučajeve. Word tokenizacija razdvaja tekst na pojedinačne reči korišćenjem razmaka i interpunkcije kao graničnika i dobro funkcioniše za neformalne tekstove na engleskom jeziku

5.1.3. Uklanjanje stop reči

Stop-reči su česte funkcionalne reči poput "the", "is", "at", "which" koje se pojavljuju u gotovo svakom tekstu i ne nose informaciju specifičnu za temu ili klasu dokumenta [8]. Njihovo uklanjanje smanjuje dimenzionalnost rečnika i ubrzava treniranje bez značajnog gubitka semantičke informacije u klasičnim modelima.

Standardne liste stop-reči dostupne su kroz biblioteke poput NLTK i spaCy i sadrže između 100 i 300 najčešćih reči engleskog jezika. Međutim, primena standardnih lista zahteva oprez jer reči koje su generalno neinformativne mogu biti važne u specifičnom kontekstu. Na primer, negacije poput "not" i "never" kritične su za analizu sentimenta i mogu biti relevantne za detekciju dezinformacija jer menjaju polaritet tvrdnji. Uklanjanje "not" iz rečenice "This is not true" menja njeno značenje u potpunosti suprotno.

Važno je naglasiti da uklanjanje stop-reči donosi najveću korist kod BoW i TF-IDF reprezentacija, dok kod dubokih modela i transformer arhitektura ovaj korak generalno nije preporučljiv. BERT i slični modeli trenirani su na punom tekstu uključujući funkcionalne reči i naučili su da koriste ove reči kao deo kontekstualnog razumevanja. Njihovim uklanjanjem narušava se distribucija ulaznih podataka u odnosu na distribuciju na kojoj je model pretreniran.

U projektu je primenjeno je uklanjanje stop reči korišćenjem NLTK liste, proširene o fanovski specifične reči (*seventeen*, *svt*, *gose*) i HTML artefakte koji su "procureli" kroz normalizaciju (*href*, *amp*, *quot*). Stop reči su česte funkcionalne reči koje se pojavljuju u gotovo svakom tekstu i ne nose informaciju specifičnu za temu [8]. Njihovim uklanjanjem smanjuje se dimenzionalnost rečnika bez značajnog gubitka semantičke informacije. Važno je napomenuti da ovaj korak nije primenjen kod BERTopic modela koji koristi Sentence Transformers odnosno jer su transformer modeli trenirani na punom tekstu i uklanjanje stop reči narušava distribuciju ulaza u odnosu na distribuciju na kojoj je model pretreniran [10].

5.1.4. Lematizacija

Lematizacija je tehnika svođenja reči na njihov osnovni oblik, sa ciljem grupisanja morfoloških varijanti iste reči u jedan token i time smanjenja dimenzionalnosti rečnika [8]. Možemo videti primer na slici 5.2.

Lematizacija svodi reči na njihov rečnički oblik, lemu, korišćenjem morfološke analize i leksičke baze podataka [7]. Na primer, "better" se lematizuje u "good", a "are" u "be". Za razliku od stemovanja, lematizacija uvek proizvodi validne reči i uzima u obzir gramatički kontekst. WordNet lemmatizer i spaCy su najčešće korišćeni alati. Mana lematizacije je veća računska složenost i potreba za POS (*Part-of-Speech*) tagovima za ispravno funkcionisanje.

5.2. Primer lematizacije i stemovanja

Svaka reč je svedena na osnovni rečnički oblik korišćenjem NLTK WordNetLemmatizer-a: running → run, episodes → episode, laughing → laugh. Lematizacija koristi morfološku analizu i leksičku bazu podataka da uvek proizvede validnu reč, za razliku od stemovanja koje mehanički odseče sufiks i može dati oblik koji nije stvarna reč [8]. Kao i uklanjanje stop reči, lematizacija nije primenjena na ulaz za BERTopic sa Sentence Transformers, iz istog razloga jer BERT koristi sopstvenu subword tokenizaciju i primena lematizacije pre njega može degradirati performanse [10].

5.2. Reprezentacija teksta

Kako bi modeli mogli da obrade tekst, svaki komentar mora biti pretvoren u numerički vektor. Veličina rečnika i dimenzionalnost vektorskog prostora direktno određuju računsku složenost i rizik od overfittinga.

Bag of Words (BOW) broji koliko puta se svaka reč iz rečnika pojavljuje u dokumentu. Rezultat je retka matrica dimenzija (broj_komentara × veličina_rečnika) sa dominacijom nula vrednosti. BOW ignoriše redosled reči i tretira svaki dokument kao neuređenu kolekciju tokena. Ovo je fundamentalno ograničenje, ali i razlog zbog kojeg je BOW računski veoma efikasan. Koristi se kao ulaz za LDA model.

TF-IDF (Term Frequency - Inverse Document Frequency) proširuje BOW dodeljujući veće težine rečima koje su česte u jednom dokumentu ali retke globalno. Time se ublažava dominacija opštih reči koje se pojavljuju u svim komentarima i koje u BOW reprezentaciji dobijaju neproporcionalno veliku težinu bez semantičke opravdanosti. TF-IDF matrica koristi se kao ulaz za NMF model, uz unigramske i bigramske termine.

Word2Vec trenira plitku neuralnu mrežu na celom korpusu da nauči distribuirane reprezentacije reči, takve da su semantički slične reči geometrijski bliske u vektorskom prostoru. Za razliku od BOW i TF-IDF koji svakoj reči dodeljuju fiksnu težinu na osnovu frekvencije, Word2Vec uči da reči "funny" i "hilarious" dele semantički prostor čak i ako se nikada ne pojavljuju u istom dokumentu. Vektor dokumenta se dobija usrednjavanjem vektora svih obrađenih tokena u komentaru i koristi se kao embedinz za BERTopic Varijantu B.

6. DETEKECIJA TEMA I ANALIZA

6.1. Statistika skupa podataka

Skup podataka prikupljen putem YouTube Data API v3 obuhvata ukupno 20 videa YouTube emisije "*Going Seventeen*" tj. 10 najgledanijih i 10 najskorije objavljenih u trenutku prikupljanja. U sirovim podacima registrovano je skoro 75.000 komentara na engleskom jeziku.

Analiza sirovih komentara potvrđuje teorijsku karakterizaciju ovog tipa teksta izloženu u poglavlju 2. Prosečan komentar sadrži oko 16 reči i 107 karaktera, raspodeljenih u dve do tri rečenice. Distribucija je desno asimetrična odnosno ogromna većina komentara je kratka i spontana, što vidimo na slici 6.1., dok su veoma dugački komentari statistički retki.

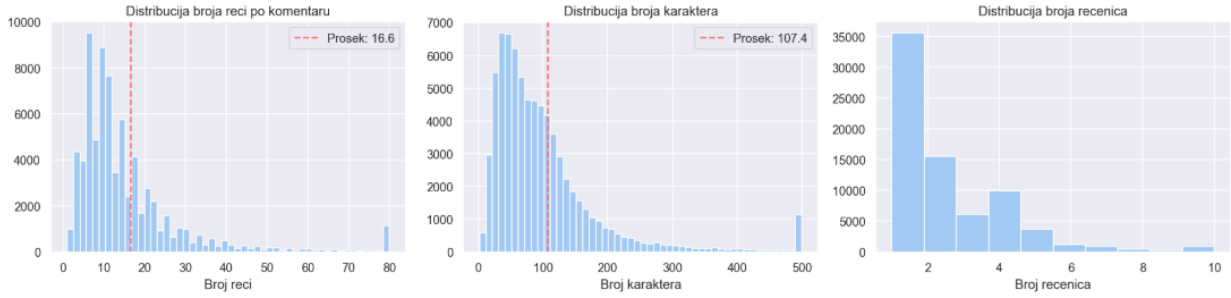

Slika 6.1. Distribucija dužine komentara (broj reči, karaktera i rečenica)

Najčešće reči u sirovim podacima koje vidimo na slici 6.2. su "watch", "youtube", "seventeen", "episode", "love" i "like", što odražava kombinaciju emotivnih reakcija i fokusa na samu emisiju, ali takođe vidimo i određeni šum kao što su reči "href", "https" i slično. Pojava imena članova grupe (Hoshi, Jeonghan, Mingyu, Seungkwan) potvrđuje da fanovi aktivno komentarišu pojedince, a prisustvo slengova (lmao, omg, ngl) ukazuje na neformalni registar diskursa. Globalni TTR (type-token ratio) iznosi oko 0,018, što je tipično za kratke neformalne tekstove sa visokim stepenom ponavljanja.

Slika 6.2. Najčešće reči na datom skupu podataka

6.2. Filtriranje i klasifikacija wish komentara

Budući da je jedan od centralnih ciljeva ovog istraživanja identifikacija tema koje fanovi žele da vide u budućim epizodama, primenjen je poseban korak filtriranja koji iz celokupnog skupa izdvaja takozvane *wish* komentare tj. komentare koji sadrže eksplicitne sugestije, molbe, izražavanje želja ili očekivanja vezanih za sadržaj emisije. Filtriranje je sprovedeno primenom skupa od 50 regularnih izraza koji pokrivaju direktne iskaze želja ("I want", "I wish", "I hope"), sugestije i preporuke ("they should", "it would be nice to"), nostalgiju i zahteve za povratkom formata ("bring back", "I miss", "we need more"), kao i implicitna očekivanja ("can't wait to see", "looking forward to"). Rezultat filtriranja je podskup od oko 4.600 wish komentara, što odgovara otprilike 6% ukupnog skupa. Najaktivniji regex paterni su "they should", "I wish" i "bring back", svaki sa nekoliko stotina pogodaka. Važno je napomenuti da regex filtriranje beleži i komentare koji pozivaju na glasanje za nagrade ili streaming pesama, koji semantički nisu sugestije za sadržaj emisije.

U cilju preliminarne karakterizacije *wish* komentara bez primene modela za detekciju tema, svaki *wish* komentar je ručno kategorisan prema definisanom rečniku od sedam kategorija: "Games and activity", "Talk show", "Group dynamic", "Emotions", "Travelling", "Music and performance" i "Repeated format". Ovo je urađeno i radi poređenja rezultata modela i toga kako bi jedan fan odvojio odrežene kategorije želja. Kategorija "Other" obuhvata komentare koji nisu svrstani ni u jednu od navedenih kategorija i ona će kasnije biti dodatno analizirana. Distribucija je prikazana na slici 6.3.

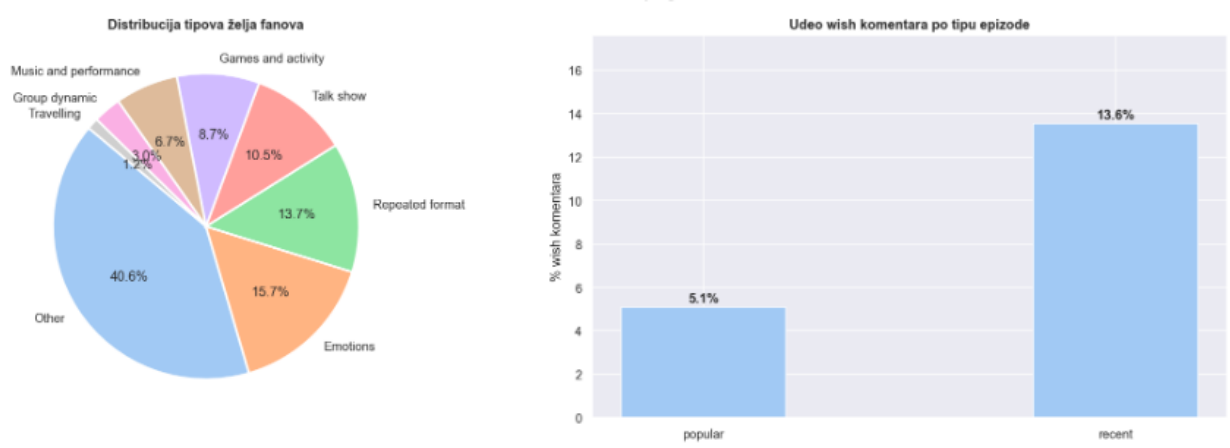

Slika 6.3. Distribucija tipova želja fanova i udeo wish komentara po tipu epizode

Najzastupljenija keyword kategorija je "Emotions", a slede je "Repeated format" i "Talk show", dok je "Travelling" najmanje zastupljena ručnom kategorizacijom. Analiza udela *wish* komentara po tipu epizode pokazuje da su popularni (stariji) videi nešto skloniji *wish* komentarima od nedavnih, što je konzistentno sa hipotezom da dugotrajna ekspozicija videa privlači nostalgični diskurs o povratku starih formata. Prosečni broj lajkova na *wish* komentarima sličan je sa *non-wish* komentarima.

6.3. Predobrada teksta

Pre primene modela za detekciju tema, komentari su podvrgnuti nizu predobradnih koraka prilagođenih specifičnostima fandom teksta na engleskom jeziku. Najpre su uklonjeni HTML tagovi, URL adrese, emotikoni i specijalni simboli, nakon čega su svi komentari konvertovani u mala slova. Tokenizacija je izvršena pomoću NLTK biblioteke, a zatim su eliminisane stop reči iz standardnog engleskog rečnika, proširenog domenski specifičnim terminima koji ne nose tematsko značenje u ovom kontekstu (poput “going”, “seventeen”, “svt”, “carat”). Lemmatizacija je primenjena korišćenjem WordNet lematizatora kako bi se svela morfološka varijabilnost reči na osnovne oblike. Za LDA model korišćen je CountVectorizer sa ograničenjem na reči koje se pojavljuju u najmanje dva dokumenta, dok je za NMF primenjen TF-IDF vektorizator koji dodatno ponderisanjem smanjuje uticaj izuzetno čestih reči. Za BERTopic modele predobrada je bila minimalnija. Zadržani su originalni tekstovi bez agresivnog uklanjanja reči, budući da Sentence Transformers i Word2Vec embedding modeli bolje funkcionišu na prirodnijim, manje izmenjenim rečenicama.

6.4. Rezultati LDA i NMF modela

LDA i NMF modeli primenjeni su na obrađene wish komentare sa TF-IDF reprezentacijom (za NMF) i BOW reprezentacijom (za LDA), uz unapred zadat broj tema K. Optimalna vrednost K određena je empirijski isprobavanjem raspona od 6 do 12 tema, što vidimo na slici 6.4. Oba modela generišu tematske grupe zasnovane na frekvenciji reči unutar obrađenog skupa.

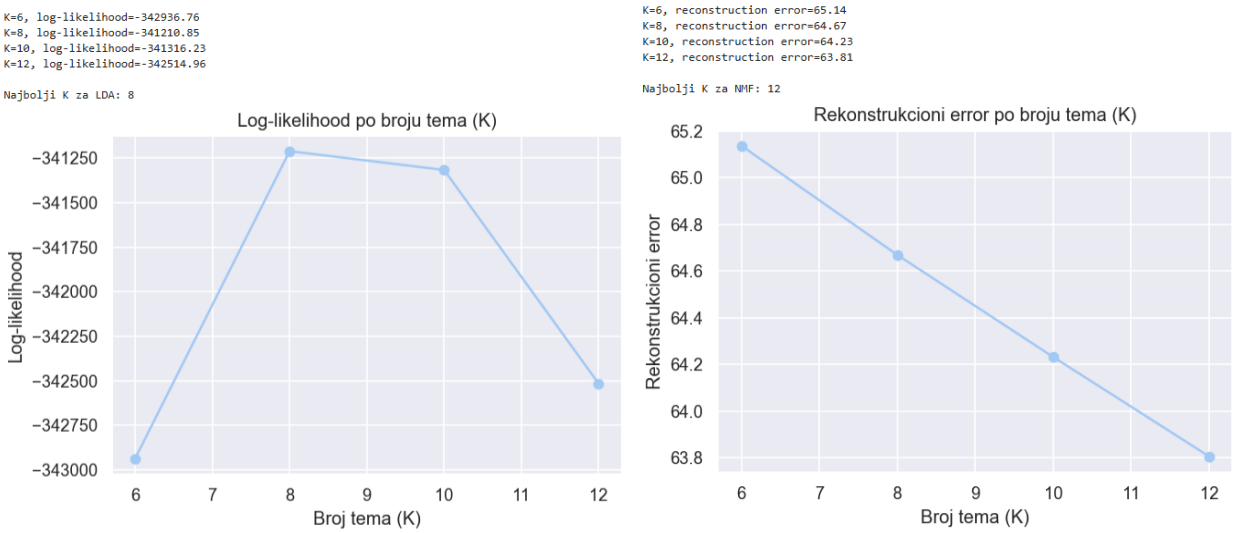

Slika 6.4. Određivanje optimalnog parametra K za model LDA i model NMF

LDA je najstariji model u ovom projektu i njegova primena na komentare od 5–10 reči otkriva ozbiljna strukturalna ograničenja. Model pretpostavlja da svaki dokument sadrži mešavinu tema, što nema smisla za kratke, često monotematske komentare, dok log-likelihood kao metrika

za selekciju broja tema favorizuje veće K vrednosti iako one ne donose bolje teme. Pregledom rezultata na slici 6.5. uočava se da većina LDA tema deli gotovo identičan vokabular generičkih reči poput “fun”, “game”, “like”, “episode” i “member” bez jasnog distinktivnog jezgra i to je direktna posledica bag-of-words reprezentacije u kojoj rečenice “i want a cooking episode” i “i want a horror episode” izgledaju gotovo identično jer razlika leži u samo jednoj reči koju model tretira ravnopravno sa svim ostalima. LDA konzistentno uspeva da izdvoji samo jednu koherentnu temu, onu oko konkretnih vlastitih imena jer su one retke, visokofrekventne i domenski specifične, što predstavlja upravo tip signala koji model može da "uhvati" čak i na kratkim tekstovima. Sve zajedno, LDA se pokazuje korisnim isključivo kao baseline model koji potvrđuje da je zadatak tematske analize kratkih komentara težak za klasične pristupe, ali ne daje interpretabilne i pouzdane uvide za ovaj skup podataka.

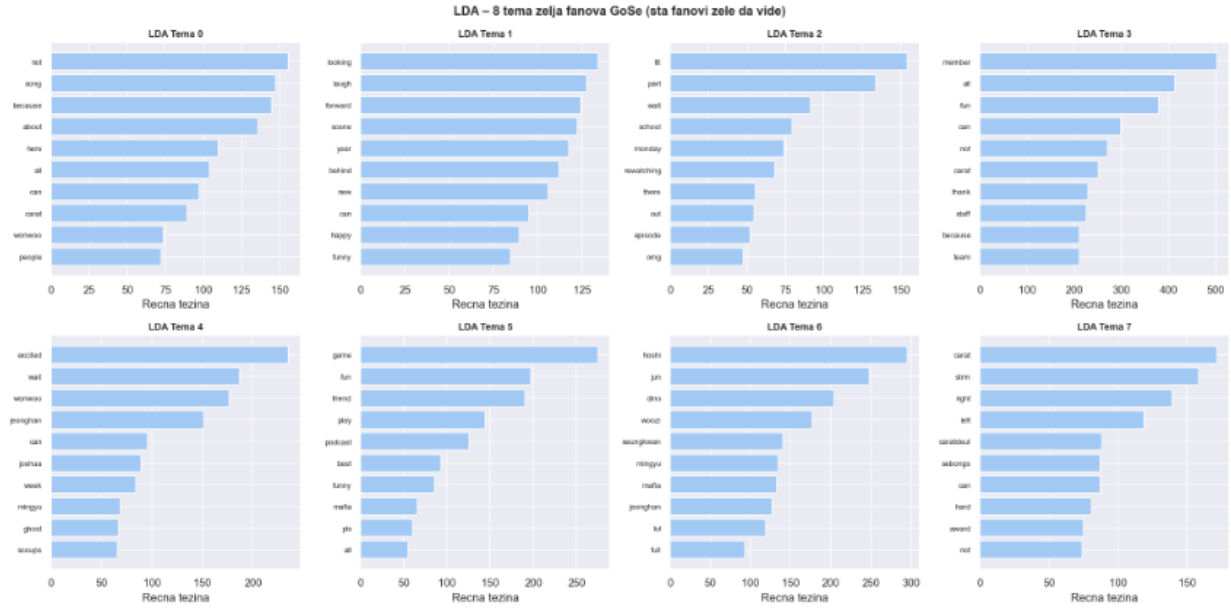

Slika 6.5. Teme otkrivene pomoću LDA modela

Za razliku od LDA, NMF daje vidljivo čistije teme gde se na slici 6.6. uočavaju jasno obrasci poput “excited”, “week”, “part”, “omg”, “monday” koji ukazuju na diskurs iščekivanja. Na kratkim tekstovima NMF obično nadmašuje LDA u koherentnosti upravo zbog TF-IDF reprezentacije, koja naglašava specifične reči a potiskuje opšte. Međutim, NMF pretpostavlja linearnu separabilnost tema, što nije uvek tačno jer komentari često kombinuju više želja (npr. “cooking horror episode with all 13 members”), pa takvi komentari doprinose svim relevantnim temama istovremeno i razređuju signal. Bigram reprezentacija pomaže kod fraza poput “bring back”, ali ne rešava problem kratkih tekstova. Dakle NMF je solidan baseline koji daje interpretabilne uvide za teme sa distinktivnim vokabularom, ali propušta suptilnije semantičke nijanse.

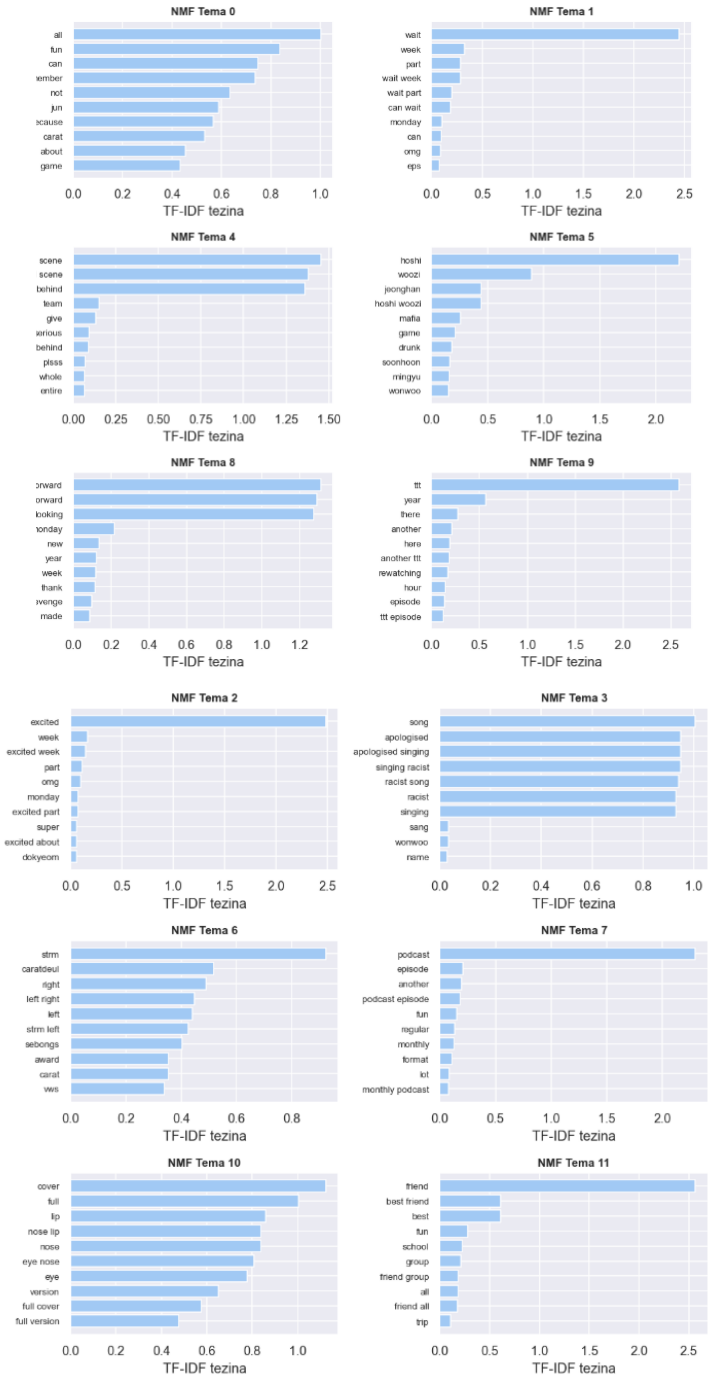

Slika 6.6. Teme otkrivene pomoću NMF modela

Oba modela primenjena su na isti preprocessovani korpus *wish* komentara, pri čemu je LDA treniran sa 8 tema, a NMF sa 12 tema, s obzirom na to da je NMF pokazivao nešto veću granularnost u raspodeli reči.

Koherencija (c_v metrika) pokazala je da LDA postiže blago bolji rezultat (0.5702) u poređenju sa NMF (0.5470). Obe vrednosti spadaju u umereni opseg, što je očekivano za kratke,

neformalne komentare sa fandom rečnikom. Takvi tekstovi su po prirodi teži za *topic* modelovanje zasnovano na *bag-of-words* reprezentaciji.

Po sadržaju, LDA teme vuku ka globalnijim, mešovitim distribucijama reči, pa su neke teme bile apstraktnije i teže za direktnu interpretaciju. NMF je, zahvaljujući svojoj aditivnoj faktorizaciji, davao nešto oštrije i jasnije teme, posebno za specifičan vokabular poput naziva formata ("mafia", "TTT", "horror") i zahteva za češćim pojavljivanjem pojedinih članova. Međutim, NMF je ponekad preterano fragmentovao srodne teme u više manjih klastera.

Zajednički nedostatak oba modela u ovom kontekstu je neosetljivost na semantički kontekst. Oba tretiraju komentare kao *bag-of-words* i ne razlikuju, na primer, "I want more mafia games" od "I don't want mafia anymore". Oba komentara imaju istu reč i mogu završiti u istoj temi. Iz tog razloga, BERTopic predstavlja semantički nadređen pristup, posebno za kratke tekstove sa implicitnim značenjem.

6.5. Rezultati BERTopic modela - Varijanta A (Sentence Transformers)

BERTopic varijanta A koristi pretreniran model all-MiniLM-L6-v2 iz biblioteke Sentence Transformers za generisanje 384-dimenzionalnih semantičkih embedinga wish komentara. Nakon redukcije dimenzionalnosti pomoću UMAP (n_neighbors=15, n_components=5, min_dist=0.0, metrika kosinusne udaljenosti) i klasterovanja pomoću HDBSCAN (min_cluster_size=30), model automatski otkriva koherentne tematske klastere bez unapred zadatog broja tema. Teme su opisane ključnim rečima generisanim c-TF-IDF procedurom.

Sentence Transformers embedinzi dobro hvataju semantiku celih fraza, što predstavlja ključnu prednost za kratke komentare kakvi dominiraju u ovom skupu podataka. Međutim, HDBSCAN može kreirati previše granularne teme, male klastere od 10 do 30 komentara, koje se teško smisleno interpretiraju, što se i pokazalo u praksi gde je model identifikovao 119 tema. Komentari u klasteru –1 (šum) nisu nužno bezvredni, jer mogu sadržati validne ali retke želje koje nisu dovoljno zastupljene za formiranje zasebnog klastera. Dodatna slabost je embedding bias gde je model all-MiniLM-L6-v2 treniran pretežno na opštem tekstu, pa K-pop terminologija i fan sleng poput "ot13", "svt" i "maknae" možda nisu optimalno reprezentovani u embedding prostoru. BERTopic varijanta A otkriva semantički bogatije i preciznije teme nego LDA ili NMF. Teme se mogu podeliti u dve kategorije.

Teme vezane za formate i aktivnosti obuhvataju sledeće klastere od kojih se pojedini vide na slici 6.7. Tema rewatcha i nostalgije grupiše komentare u kojima fanovi iskazuju želju da ponovo gledaju omiljene epizode i vraćaju se klasičnim formatima. Tema talk show i podcast formata jasno je definisana pojmovima "talk", "conversation", "podcast" i "q&a", gde fanovi žele da čuju članove kako razgovaraju bez unapred zadate strukture. Tema školskih epizoda odražava nostalgiju za formatima popularnim u ranijim sezonama. Mafia igre predstavljaju jedan od jačih klastera, pri čemu fanovi izrazito traže povratak ovog formata. Hyperrealism(TTT) format prepoznat je kao zasebna tema, što govori da fanovi imaju jasnu predstavu o konkretnim segmentima koje vole. Glumački izazovi iako se ne vide na slici 6.7., opisani rečima "act", "acting", "drama", formiraju prepoznatljiv klaster odvojen od opštih igara. Behind the scenes tema

grupiše komentare sa rečima “behind”, “backstage”, “real”, gde fanovi žele uvid u ono što se dešava iza kamera.

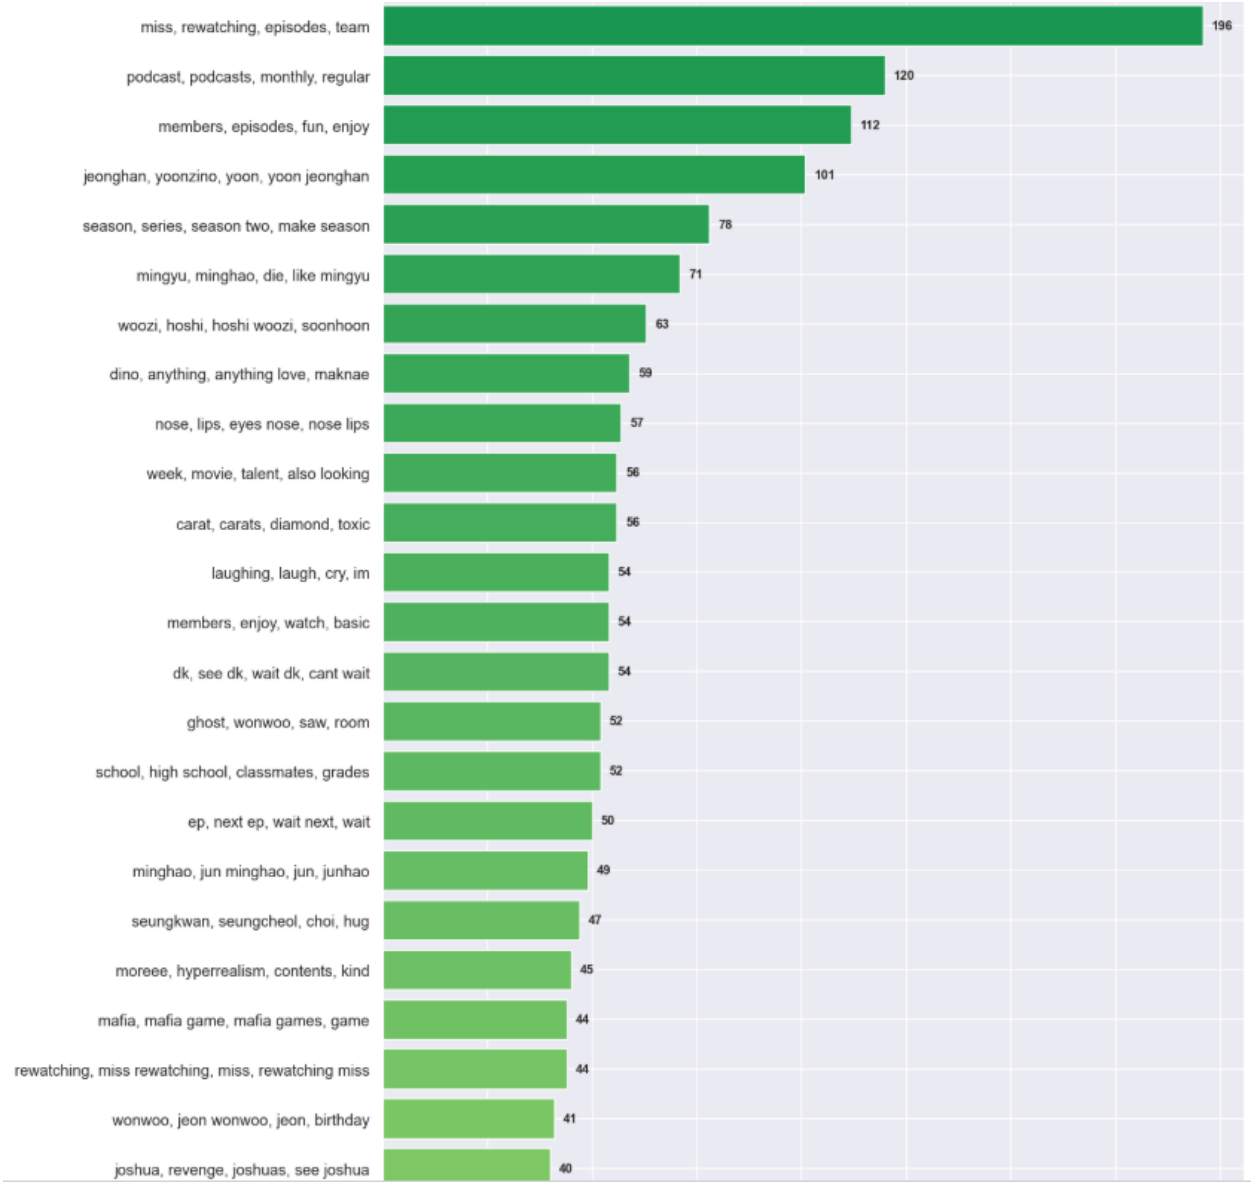

Slika 6.7. Prvih nekoliko tema detektovanih BERTopic modelom u varijanti A

Teme vezane za specifične epizode u datasetu uključuju sledeće klastere. Tema “Yeonzino i Jeonghan rap” specifično je vezana za epizode u kojima Jeonghan repuje pod pseudonimom Yeonzino, a fanovi traže više sličnog sadržaja. Tema “Wonwoo i Tag” nastala je kao reakcija na Wonwoo-ovu hrabrost u toj epizodi. “Vernon i TTT” spavanje predstavlja komični momenat koji je formirao prepoznatljiv klaster. Tema “Eyes, Nose, Lips cover” odnosi se na cover izvođenje jednog člana, a fanovi traže više muzičkih *cover* segmenata. Jun i više prisustva jasna je tema u kojoj fanovi zahtevaju da se Jun više pojavljuje i govori u epizodama. Klaster glasanja za nagrade, opisan rečima “vote”, “award”, “first place” i “chart”, predstavlja šum koji je *wish regex* uhvatio, ali koji ne odražava sugestije za sadržaj emisije i trebalo bi ga filtrirati u budućim iteracijama.

Tema arapskih i stranih prevoda grupiše komentare fanova koji ne govore engleski, a koji traže prevode na arapski i druge jezike.

Slika 6.8. UMAP 2D projekcija embedding prostora - varijanta A (Sentence Transformers)

Na 2D UMAP projekciji na slici 6.8. jasno su vidljiva odvojena "ostrva" tačaka koja odgovaraju pojedinim temama, sa gustim jezgrom i ređom periferijom koja prelazi u šum (sive tačke). Ova vizuelna separabilnost potvrđuje da Sentence Transformers embedinzi uspešno odvajaju semantičke kategorije čak i u skupu kratkih neformalnih tekstova. Procenat komentara u temi -1 (šum) iznosi 23.3%, što je prihvatljivo za ovaj tip podataka i ukazuje na to da znatan deo komentara nema dovoljno jasan ili specifičan semantički signal za klasterovanje.

6.6. Rezultati BERTopic modela - Varijanta B (Word2Vec)

BERTopic varijanta B koristi Word2Vec model treniran na samom skupu *wish* komentara (vector_size=100, window=5, min_count=2), pri čemu je vektorska reprezentacija svakog komentara dobijena usrednjavanjem vektora njegovih tokena. Isti UMAP i HDBSCAN pipeline primenjen je na 100-dimenzionalnim Word2Vec embedinzima. Iako Word2Vec treniran na domenskom skupu podataka bolje prepoznaje specifičan vokabular poput *K-pop* slenga i naziva članova u poređenju sa opšte-namenskim ST modelom, trening skup je premali za pouzdane vektorske reprezentacije. "Pravilo palca" nalaže minimum 10 miliona tokena za stabilne Word2Vec vektore, dok ovaj skup sadrži svega nekoliko hiljada komentara. Dodatno, mean pooling agregacija gubi redosled reči i negacije, pa se fraza "don't want" tretira identično kao "want". Za razliku od Sentence Transformers modela, Word2Vec ne modeluje direktno značenje cele rečenice, što predstavlja ograničenje kod kratkih i kontekstualno bogatih komentara.

Primenom u kombinaciji sa HDBSCAN algoritmom primećuje se formiranje većeg broja klastera koji su leksički slični, ali semantički plići. Teme su zasnovane na ponavljanju istih reči, a ne na dubljem značenju komentara.

Teme vezane za formate i aktivnosti od kojih se neke vide na slici 6.9. obuhvataju sledeće klastere. *Mafia* igre predstavljaju jedan od stabilnijih klastera zahvaljujući specifičnoj terminologiji poput “mafia”, “citizen” i “voted”. “TTT” format zbog svog karakterističnog naziva Word2Vec lako grupiše u zasebnu temu. Podcast i razgovorni formati prepoznati su kroz reči “talk”, “listen” i “talking”, a “behind the scenes” tema jasno je izdvojena rečima “behind”, “scene” i “backstage”.

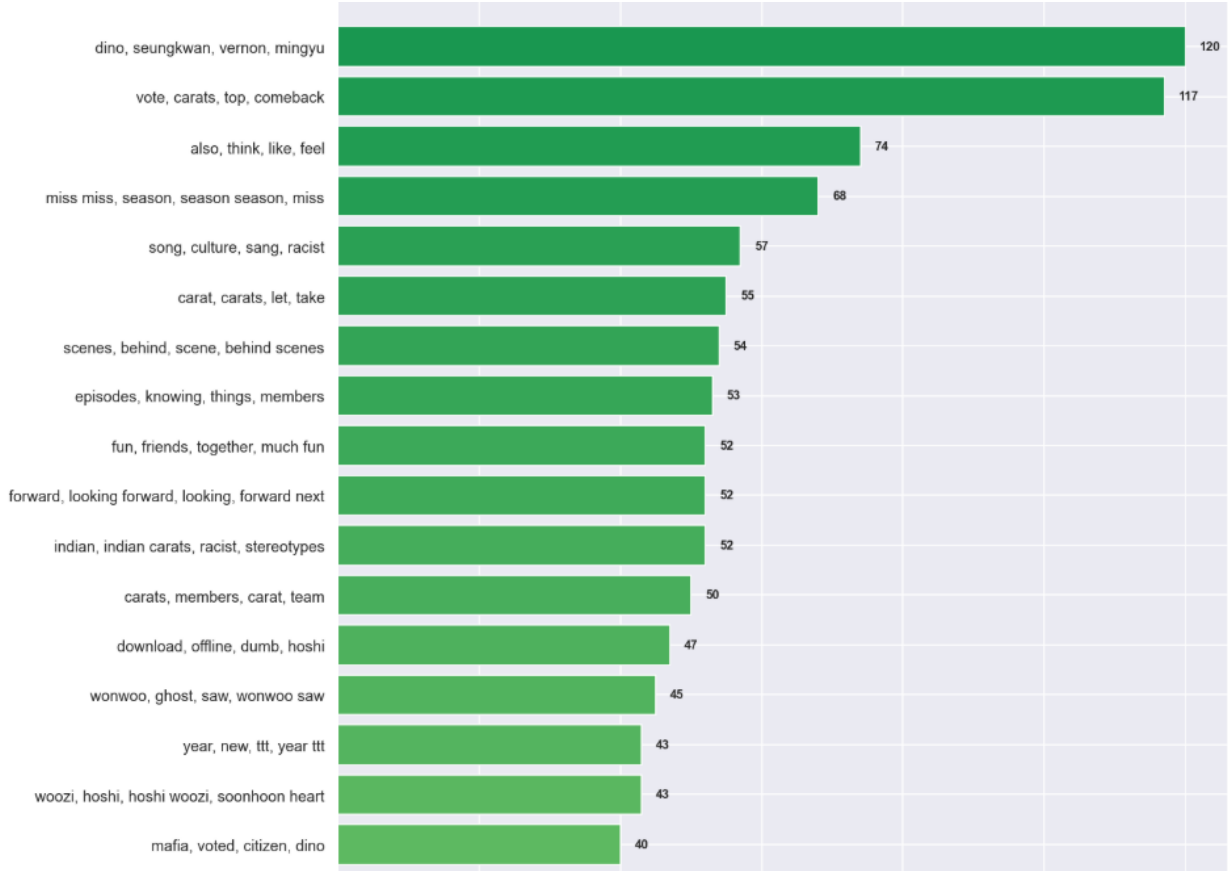

Slika 6.9. Prvih nekoliko tema detektovanih BERTopic modelom u varijanti B

Teme vezane za ponašanje i iskustvo gledanja obuhvataju sledeće klastere. Tema zabave članova, ukazuje da je percepcija zabave ključna za publiku. Emocionalna povezanost odražava se u klasterima sa rečima “miss”, “love” i “comfort”. Nostalgija je prepoznata kroz reči “miss”, “miss season”, kao želja za povratkom starijih epizoda i formata. Zahtevi za više *screen time*-a grupisani su oko reči “screen”, “time” i “more”, dok su potrebe za titlovima i prevodima prepoznate kroz reči “sub”, “subtitle” i “language”. Tema fan ideja i predloga, opisana rečima “idea”, “suggest” i “should”, pojavljuje se u više klastera, ali često bez dovoljne koherentnosti zbog ograničenja modela.

U poređenju sa Varijantom A, Word2Vec daje manje precizne i više fragmentisane teme, ali i dalje može biti koristan za identifikaciju najčešćih pojmova i osnovnih trendova u komentarima.

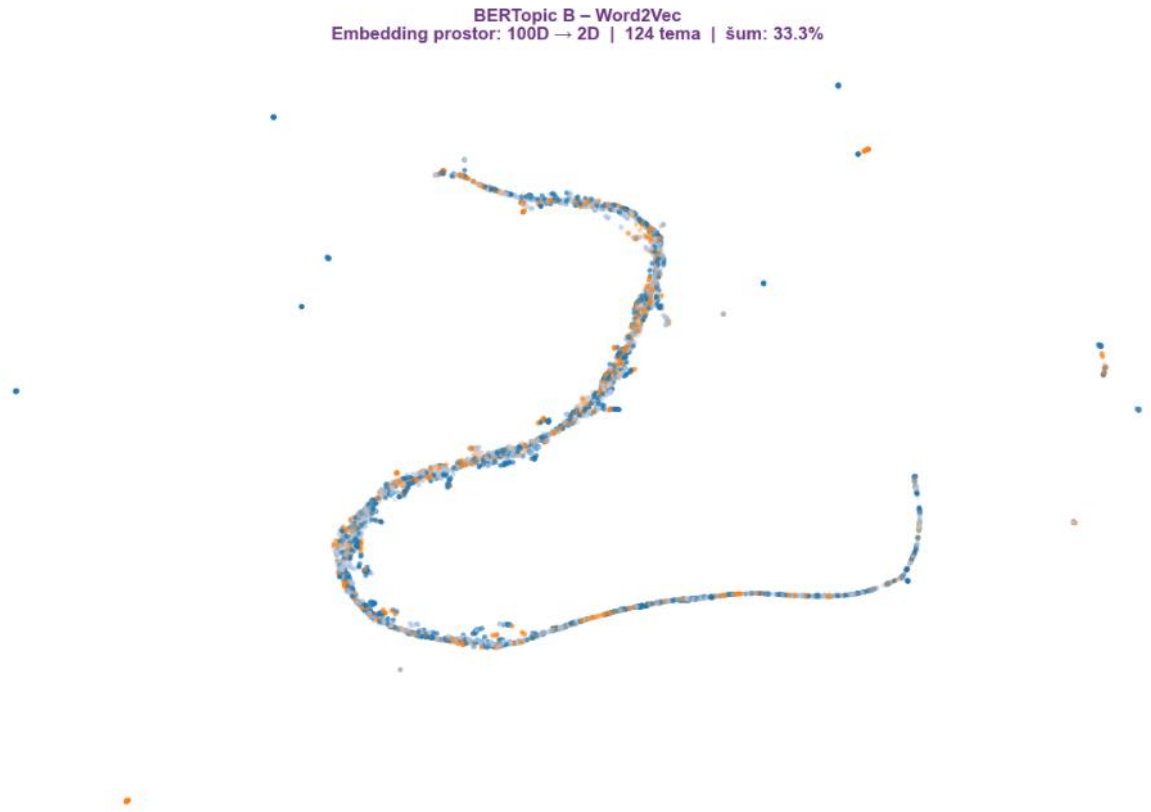

Slika 6.10. UMAP 2D projekcija embedding prostora - varijanta B (Word2Vec)

Na 2D projekciji Word2Vec prostora na slici 6.10. embeding oblak je difuzniji i manje jasno strukturiran. To je posledica dve fundamentalne osobine ove varijante, prva je mala veličina trening skupa (nekoliko hiljada komentara naspram preporučenih desetak miliona tokena za stabilne Word2Vec vektore), a druga je *mean pooling* agregacija koja gubi redosled reči i negacije. Klaster koji sadrži frazu "don't want" tretira se identično kao klaster sa "want" jer usrednjena reprezentacija ne razlikuje polaritet.

6.7. Komparativna analiza svih modela

Tabela na slici 6.11. prikazuje kvantitativne metrike za sve četiri evaluirane varijante modela. Koherentnost teme (c_v) merena je samo za LDA i NMF jer HDBSCAN u kombinaciji sa semantičkim embedinzima ne garantuje tematsku separaciju po leksičkom principu na kome se c_v zasniva. Za BERTopic varijante mereni su raznolikost tema (topic diversity), procenat šuma i prosečna veličina klastera.

Model	Br. tema	Koh. c_v	Diversity	Šum %	Avg. veličina
LDA	8	0.5702	–	–	–
NMF	12	0.5470	–	–	–
BERTopic A (SentTransf)	119	–	0.7655	23.3%	29.9
BERTopic B (Word2Vec)	124	–	0.7161	33.3%	24.9

Slika 6.11. Komparativna evaluacija modela

Ključna opažanja iz komparativne analize mogu se sažeti na sledeći način. LDA blago nadmašuje NMF po c_v metrici (0.5702 naspram 0.5470), što je donekle iznenađujuće s obzirom na literaturu koja ukazuje da NMF bolje funkcioniše na kratkim tekstovima. Razlika je ipak mala i oba modela spadaju u umereni opseg koherentnosti. Broj tema kod LDA i NMF mora biti zadat unapred i empirijski je određen na 8 odnosno 12 za ovaj skup. BERTopic Varijanta A (Sentence Transformers) generiše semantički najpreciznije i najinterpretabilnije teme, sa jasno odvojenim semantičkim kategorijama, diversity skorom 0.7655 i umerenim procentom šuma od 23.3%. BERTopic Varijanta B (Word2Vec) identifikuje 124 tema uz veći procenat šuma od 33.3% i *diversity* skor 0.7161, i generalno je inferiornija od varijante A na ovom skupu zbog malog trening korpusa i ograničenja *mean pooling* agregacije.

6.8. Automatsko otkrivanje podoblasti u kategoriji "Other"

Značajan deo *wish* komentara nije mogao biti svrstan u sedam manuelno definisanih kategorija i klasifikovan je kao Other. Kako bi se identifikovale latentne podoblasti unutar ovog dela, primenjen je odvojeni BERTopic model isključivo na Other komentare, sa blažim HDBSCAN parametrima (min_cluster_size=6) radi otkrivanja sitnijih semantičkih grupacija. Otkrivene podoblasti uključuju teme vezane za dostupnost prevoda i titlova ("subtitle", "language", "translation"), teme o emotivnoj i porodičnoj dinamici unutar grupe ("comfort", "family", "bond"), teme vezane za specifičan humor i unutrašnje šale zajednice ("reference", "funny moment") i teme o muzičkim nastupima van emisije ("concert", "stage", "performance"). Ovaj nalaz potvrđuje da keyword klasifikacija sistematski potcenjuje semantičku raznolikost komentara i da model detektuje smislene kategorije kojih u ručnom rečniku nema.

Ključni nalazi istraživanja mogu se sažeti kroz preporuke za kreatore sadržaja. Formati sa najviše potražnje su "mafia/role-play" igre, horor i "escape room" format te "TTT" format, koji konzistentno dominiraju u wish komentarima. Fanovi jasno traže povratak interaktivnih, napetih formata sa elementima igre. Pored toga, primetan je zahtev za više OT13 (svih 13 članova) sadržaja i veće zastupljenosti manje vidljivih članova, pre svih Juna i The8-a. "Talk show i podcast" format prepoznat je kao zasebna tema, a zahtevi za više titlova i prevoda ukazuju na globalnost fanske zajednice koja nije u potpunosti uslužena samo engleskim prevodima.

6.9. Analiza po članovima grupe i tipu epizode

Posebna analiza *wish* komentara po pominjanju članova grupe gde slika 6.12. pokazuje da Jun, Hoshi i DK imaju najveći broj *wish* pominjanja i da prednjače po prosečnom broju lajkova na komentarima koji ih pominju, što BERTopic tema za screen time interpretira kao signal zajedničkog glasa zajednice koji traži veću zastupljenost ovih članova. Dominantne BERTopic teme za komentare koji pominju Juna su “screen time” i “more presence”, što je direktno konzistentno sa poznatim narativom unutar *Carat* zajednice o nedovoljnoj vidljivosti pojedinih članova u video sadržaju, budući da je Jun jako tih i da je iz Kine, gde stalno putuje zbog solo projekata.

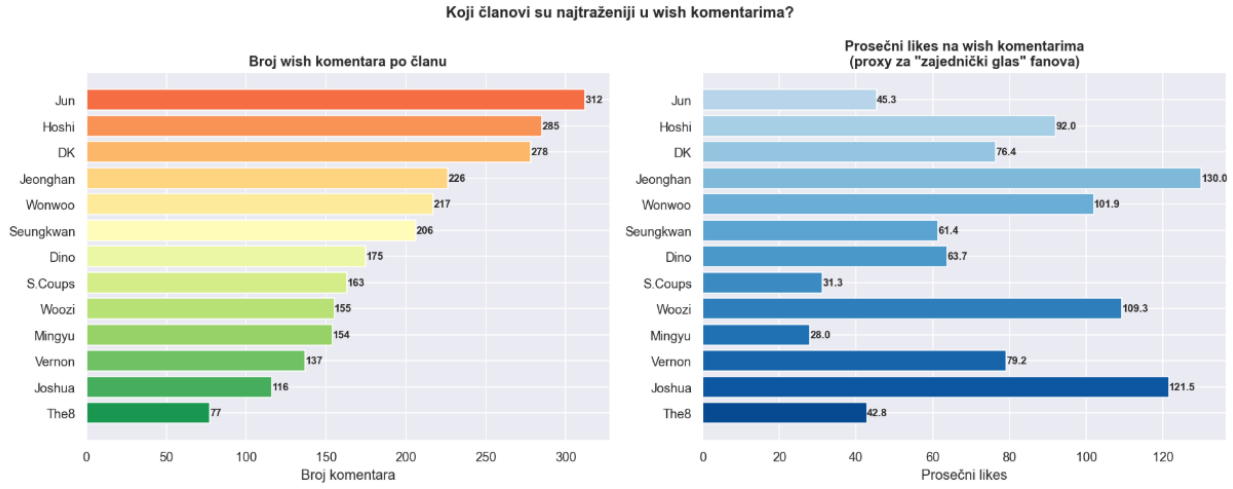

Slika 6.12. Broj wish komentara i prosečni lajkovi po članu grupe

Analiza po tipu epizode (popular vs. recent) podeljenih ručno u kategorije otkriva izražene razlike u distribuciji želja. Kod popularnih (starih) epizoda, najveći udeo ima kategorija "Other" sa 45%, zatim "Emotions" sa 16% i "Repeated format" sa 13%, dok kod nedavnih (novih) epizoda dominira takođe "Other" sa 28%, ali znatno veći procenat zauzimaju "Talk show" sa 24% i "Emotions" sa 15%. Najdrastičnija razlika uočava se u kategoriji "Music and performance", koja pada sa 9% na svega 2%, kao i u kategoriji "Talk show", koja raste sa 5% na 24%. Ove razlike vidljive su na slici 6.13. koja prikazuje distribuciju wish kategorija po tipu epizode.

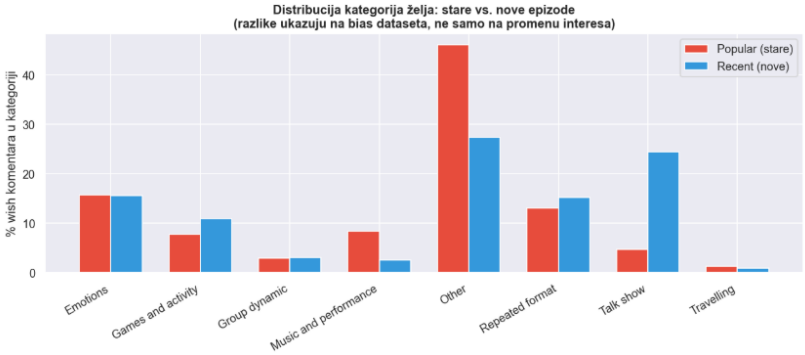

Slika 6.13. Distribucija *wish* kategorija: stare vs. nove epizode

7. NEDOSTACI I POTENCIJALNA UNAPREĐENJA

Uprkos pozitivnim rezultatima, istraživanje ima nekoliko metodoloških ograničenja koja treba uzeti u obzir pri interpretaciji nalaza i koja otvaraju pravce za buduća unapređenja.

Najznačajnije metodološko ograničenje je jezičko ograničenje analize. Filtriranje komentara na engleskom jeziku primenjeno je već u fazi prikupljanja podataka, što znači da korejski, kineski, španski, portugalski i ostali komentari nisu obuhvaćeni nijednim delom analize. Korejska fan zajednica numerički je veoma zastupljena i njen diskurs može se suštinski razlikovati od engleskog. Višejezična analiza primenom modela *paraphrase-multilingual-MiniLM-L12-v*2 iz biblioteke Sentence Transformers bi omogućila celovitiji uvid u teme fanske zajednice, ali uvodi dodatne izazove vezane za kvalitet mašinskog prevoda i semantičku koherentnost embedinga kroz jezike.

Drugi značajan nedostatak je ograničeni obuhvat *wish* filtera zasnovanog na regularnim izrazima. *Regex* pristup je transparentan i ponovljiv, ali ne garantuje potpun odyiv gde fraze poput "imagine them doing horror" ili "that cooking episode would be insane" semantički su *wish* komentari ali ih *regex* ne hvata jer ne odgovaraju nijednom od definisanih šablona. Procenjuje se da stvarni procenat *wish* komentara može biti 5-10 procenata viši od izmerenog. Pored toga, regex hvata i komentare koji sadrže pozive na glasanje za muzičke nagrade ili streaming pesama, koji nisu sadržajne sugestije za emisiju. Oba ova problema bi se mogla rešiti fine-tuningom BERT klasifikatora na ručno anotiranom uzorku od 500-1000 komentara.

Treće ograničenje je selektivni bias skupa podataka. Skup obuhvata samo 10 najgledanijih i 10 najnovijih videa kanala, što je mali i potencijalno nereprezentativni uzorak celokupne produkcije "*Going Seventeedn*". Popularni videi imaju eksponencijalno više komentara od nedavnih, pa nalazi u velikoj meri odražavaju mišljenja gledaoca najgledanijih epizoda. Proširenje skupa na sve epizode bi smanjilo ovaj bias i omogućilo temporalnu analizu odnosno praćenje kako se teme menjaju kroz sezone emisije.

Četvrto ograničenje je to što analiza komentara u šumu (BERTopic klaster -1) nije sprovedena u punom obimu. Komentari koje HDBSCAN nije mogao da klasterizuje nisu nužno bezvredni, mnogi verovatno sadrže validne ali retke ili visoko idiomatske sugestije koje modeli ne uspevaju da grupišu. Specijalizovana analiza outlier komentara, na primer primenom zero-shot klasifikacije na bazi *language model prompting*-a, bila bi vredan doprinos ukupnoj slici.

Peto potencijalno unapređenje odnosi se na evaluaciju modela. Trenutna evaluacija oslanja se na automatske metrike (c_v koherentnost, topic diversity, silhouette score) i ručnu inspekciju uzoraka. Formalna human evaluation u kojoj bi domenski eksperti (iskusni fanovi ili istraživači K-pop kulture) ocenjivali interpretabilnost i smislenost tema bi pružila čvršću empirijsku osnovu za tvrdnje o kvalitetu modela. Konačno, primena naprednih BERTopic varijanti koje koriste *large language models* za generisanje opisnih naziva tema (umesto top-n ključnih reči) mogla bi poboljšati interpretabilnost izlaza, posebno za neformalni domenski vokabular koji karakteriše ovaj skup podataka.

ZAKLJUČAK

Ovaj rad predstavlja istraživanje primene savremenih metoda za detekciju tema na skupu *YouTube* komentara fanova emisije "*Going Seventeen*". Centralni istraživački problem bio je identifikacija latentnih tematskih struktura u nestrukturiranim kratkim tekstovima koji obiluju slengom, emotikonima i kulturno specifičnim referencama, sa posebnim fokusom na komentare koji izražavaju želje i sugestije fanova o budućem sadržaju emisije. Pored toga, cilj je bio empirijsko poređenje BERTopic modela sa klasičnim pristupima kao što su LDA i NMF, te poređenje dve varijante BERTopic pipeline-a koje se razlikuju u metodi generisanja embedinga.

Iz teorijskog pregleda u prvom delu rada jasno proilazi da su *YouTube* komentari izuzetno zahtevni za primenu NLP tehnika zbog kratkoće i fragmentarnosti, neformalnog vokabulara i slenga, višejezičnosti i repetitivnosti. Upravo ove karakteristike motivišu odabir BERTopic modela kao primarnog alata, jer za razliku od LDA i NMF koji počivaju na *bag-of-words* reprezentaciji, BERTopic koristi semantičke embedinge koji razumeju kontekstualno značenje teksta. Ovo je teorijska hipoteza koju eksperimentalni rezultati potvrđuju.

Eksperimentalni rezultati pokazuju da BERTopic sa Sentence Transformers embedinzima (Varijanta A) generiše semantički najpreciznije i najinterpretabilnije teme od svih evaluiranih modela, automatski identifikujući koherentne klastere poput potražnje za „Mafia" i „role-play" igrama, „horor" i „escape room" formatom, „TTT" formatom, „podcast" i „talk show" sadržajem, te zahteva za ravnomernijom zastupljenošću svih članova grupe. LDA postiže nešto višu koherentnost od NMF, ali oba klasična modela ne uspevaju da uhvate semantičku srodnost komentara koji dele nameru ali ne i vokabular. BERTopic sa Word2Vec embedinzima (Varijanta B) inferioran je u poređenju sa Varijantom A zbog premalih trening podataka i ograničenja „mean pooling" agregacije.

Analiza *wish* komentara po tipu epizode potvrđuje istraživačku hipotezu o razlici između diskursa uz stare i nove epizode. Komentari sa popularnih, starijih videa u većoj meri odražavaju nostalgiju i pozive na povratak starih formata, dok komentari uz nedavne epizode više sadrže reaktivne sugestije vezane za aktuelni sadržaj. Analiza po članovima grupe identifikuje konzistentan obrazac da se Jun pominje u wish komentarima sa natprosečnim brojem lajkova, što je interpretabilno kao signal zajedničkog glasa koji traži veću vidljivost ovog člana. Pored toga, analiza je otkrila da *wish regex* hvata i komentare koji pozivaju na glasanje za nagrade i *streaming* pesama. Ovi komentari nisu sugestije za sadržaj emisije i predstavljaju šum koji bi trebalo filtrirati u budućim iteracijama.

Sa metodološke strane, ovaj rad demonstrira vrednost kombinovanja *regex*-baziranog filtriranja sa nesupervisovanim modeliranjem tema. *Keyword* pristup obezbeđuje transparentnost i ponovljivost, dok BERTopic otkriva finu semantičku granulaciju unutar identifikovanih kategorija. Posebno je ilustrativna analiza kategorije Other, gde BERTopic otkriva smislene podoblasti kao što su igre, prevodi i titlovi, emocionalna dinamika grupe, specifičan humor zajednice, koje je ručna kategorizacija sistematski propušta.

Istraživanje ima i praktičnu dimenziju gde su ključni nalazi neposredno upotrebljivi za informisanje kreativnih odluka produkcijskog tima emisije. Identifikovani obrasci nisu subjektivne procene već empirijski zasnovane na reprezentativnom uzorku glasova fan zajednice.

LITERATURA

[1] Slotta, D. (n.d.). *Topic: YouTube*. Statista. https://www.statista.com/topics/2019/youtube/#topicOverview

[2] (PDF) a topic modeling comparison between LDA, NMF, Top2Vec, and Bertopic to demystify twitter posts. (n.d.-k). https://www.researchgate.net/publication/360410995_A_Topic_Modeling_Comparison_Between_LDA_NMF_Top2Vec_and_BERTopic_to_Demystify_Twitter_Posts

[3] (PDF) learning the parts of objects by non-negative matrix factorization. (n.d.-l). https://www.researchgate.net/publication/12752937_Learning_the_Parts_of_Objects_by_Non-Negative_Matrix_Factorization

[4] Arora, S., Ge, R., Halpern, Y., Mimno, D., Moitra, A., Sontag, D., Wu, Y., & Zhu, M. (2013, May 13). *A practical algorithm for topic modeling with provable guarantees*. PMLR. https://proceedings.mlr.press/v28/arora13.html

[5] *Uniform manifold approximation and projection for dimension reduction*. UMAP. (n.d.). https://umap-learn.readthedocs.io/

[6] Thelwall, M. (2017b). Social Media Analytics for YouTube comments: Potential and limitations. *International Journal of Social Research Methodology*, *21*(3), 303–316. https://doi.org/10.1080/13645579.2017.1381821

[7] I. C. Mogotsi, "Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze: Introduction to information retrieval - discover computing," SpringerLink, https://link.springer.com/article/10.1007/s10791-009-9115-y (accessed Apr. 11, 2026).

[8] Xue, N. (2010). Steven Bird, Evan Klein and Edward Loper. natural language processing with python. O'Reilly Media, Inc.2009. ISBN: 978-0-596-51649-9. *Natural Language Engineering*, *17*(3), 419–424. https://doi.org/10.1017/s1351324910000306

[9] *Mining Text Data*. Boston, MA: Springer US, 2012.

[10] Goodfellow, I., Bengio, Y., & Courville, A. (2017b). *Deep learning*. The MIT Press.